Screen2Sleep AI: Proje Raporu

Proje Özeti

Screen2Sleep AI, kullanıcı gece bir uygulama oturumunun içindeyken o oturumun ne kadar daha süreceğini tahmin eden ve bunun uykuya toplam bedelini anında gösteren bir Android asistanıdır. Bedel iki parçadan oluşur: telefonda geçen sürenin doğrudan uykudan düşmesi ve kullanımın uykuya dalmayı geciktirmesiyle gelen ek kayıp.

Problem. Gece yatakta, özellikle kısa video ve sosyal medya uygulamalarında süren kullanım uyku süresini kısaltır ve uykuya dalmayı geciktirir. Kullanıcılar bu bedeli genellikle küçümser.

Hedef grup. Sabah uyanma saati sabit olan 18 yaş üstü üniversite öğrencileri ve genç yetişkinler. Bu grupta yatma saatindeki her gecikme doğrudan uykudan düşer.

Temel fikir: toplam çalınan uyku.

Çalınan uyku = Hedef yatma saatini aşan kullanım (hesap) + Ek uykuya dalma süresi (Model B)

Örnek mesaj: "Instagram oturumların bu saatte genellikle 20–40 dk daha sürüyor. Bu, hedef yatma saatini yaklaşık 25 dk aşman ve uykuya dalman yaklaşık 10 dk daha gecikmesi demek: bu gece yaklaşık 35 dk uyku kaybı." Kesin ifadeler veri analizinden sonra belirlenecektir; karar her zaman kullanıcıdadır.

Neden yapay zekâ? Devam eden bir oturumun kalan süresi uygulamaya, saate, güne, o günkü kullanıma ve kişinin alışkanlığına bağlıdır; elle kural yazılamaz (Model A). Kullanımın uykuya dalma süresine etkisi de kişiden kişiye değişir ve veriden tahmin edilmesi gerekir (Model B). Her iki model de basit bir referans yöntemi (kullanıcının medyan oturum süresi, kullanıcının ortalama uykuya dalma süresi) anlamlı biçimde geçtiği ölçüde savunulur.

Araştırma soruları.

1. **AS1:** Bir uygulama oturumunun kalan süresi, oturumun o ana kadarki süresi ve bağlam bilgisiyle ne doğrulukla tahmin edilebilir?
2. **AS2:** Yatma öncesi telefon kullanımı uykuya dalma süresini (veya yatakta kaybedilen süreyi) kişi içi düzeyde ne kadar artırır?
3. **AS3:** Bu iki tahmini birleştiren açıklanabilir, anlık bir uyarı nasıl tasarlanmalıdır?
4. **AS4:** Sistem Android'de KVKK'ya ve kullanıcı özerkliğine uygun olarak nasıl hayata geçirilir?

Sistem Mimarisi

Sistem, farklı veri setleriyle eğitilen iki modelden oluşur. Bu modeller tek bir ortak değişken üzerinden konuşur: yatma öncesi kullanım dakikası, kişinin normaline göre.

İki model, ortak bir kullanım dakikası üzerinden bağlanır



Screen2Sleep mimarisi · 2 model, 1 arayüz değişkeni

Sol taraftaki açık veri setleri modellere başlangıç bilgisini verir; sağ taraftaki kullanıcı verisi ise modelleri zamanla kişiye uyarlar.

Bileşen	**Görevi**	**Eğitim verisi**	**Kişiselleştirme**	**Referans yöntem (geçilmesi gereken)**
Model A	Devam eden oturumun kalan süresini aralıkla tahmin eder (sağkalım / kalan süre problemi)	LSApp	Kullanıcının UsageStats geçmişi	Kişinin o uygulamadaki medyan oturum süresi − geçen süre
Arayüz değişkeni	Model A çıktısını yatma öncesi toplam kullanıma çevirir	—	Kişinin normal akşam kullanımı	—
Model B	Bu kullanım miktarına karşılık gelen ek uykuya dalma süresini tahmin eder (karma etkili model)	GLOBEM	Health Connect uyku verisi	Kişinin ortalama uykuya dalma süresi
Hesap	Hedef yatma saatini aşan kullanımı bulur	—	Kullanıcının hedef saati	—

Çalışma modları.

- **Tüm gün, pasif:** Uygulama oturumları sistem geçmişinden günde birkaç kez okunur; bildirim yoktur, pil maliyeti düşüktür. Gündüz oturumları Model A'nın kişiselleştirilmesi için eğitim verisidir.
- **Akşam penceresi, aktif:** İlk prototipte hedef yatma saatinden 60 dakika önce başlayan bir izleme penceresi kullanılacaktır. Bu 60 dakika araştırma sonucu değil, pilotta test edilecek başlangıç tasarım parametresidir. Oturumlar bu sınırlı pencerede izlenir, modeller çalışır ve yalnızca karar kuralı karşılanırsa uyarı gösterilir. Kullanıcı "önemli" derse o oturumda sessiz kalınır.
- **Hedef saatten sonra:** Uykuyu bölmemek için hiçbir bildirim gönderilmez.

Kişiselleştirme döngüsü. İlk gecelerde açık veri setleriyle eğitilmiş popülasyon modelleri kullanılır. Her sabah gerçek uyku verisi yeni bir etiket olarak eklenir. Yaklaşık 2–3 hafta sonra her iki model de büyük ölçüde kullanıcının kendi verisine dayanır.

Bölüm 1: Literatür Taraması

1.1 Giriş

Akıllı telefonlar gün boyu yanımızda olduğu gibi, gecenin son ve sabahın ilk etkileşimini de çoğu zaman bunlar oluşturuyor. Yatma saati civarındaki telefon kullanımı, uyku sağlığı açısından değiştirilebilir bir risk faktörü olarak giderek daha fazla ilgi görüyor. Erken derlemeler ekran kullanımının uykuyu üç yolla etkileyebileceğini öne sürdü: uykudan zaman çalarak, içerik ve sosyal etkileşim yoluyla uyarılmayı artırarak ve ekran ışığıyla sirkadiyen ritmi geciktirerek (Cain & Gradisar, 2010). Ancak güncel kuramsal çalışmalar bu ilişkinin tek yönlü olmadığını, uyku sorunlarının da gece telefon kullanımını tetikleyebileceğini gösteriyor (Bauducco ve ark., 2024).

Bu literatür taraması, projenin dayandığı dört soruyu sırayla ele alıyor: (1) Yatma öncesi telefon kullanımı uykuyu, özellikle uykuya dalma süresini nasıl etkiliyor ve bu etki nasıl ölçülür? (2) Kullanıcının o anki telefon oturumunun ne kadar süreceği önceden tahmin edilebilir mi? (3) Kişiler arası farklar düşünüldüğünde bu tahmin kişiye nasıl uyarlanabilir? (4) Doğru anda yapılacak bir müdahale, kullanıcının özerkliğine saygı göstererek nasıl tasarlanabilir?

Son olarak, anlık uyarlanabilir müdahale (just-in-time adaptive intervention; JITAI), desteğin kişinin değişen bağlamına, ihtiyacına ve müdahaleye açık olduğu ana göre sunulmasını önerir (Nahum-Shani ve ark., 2018). Dijital öz-denetim araçları yalnızca kullanım süresini sınırlamakla kalmaz; kişinin otomatikleşmiş davranışı fark etmesine, kısa bir duraklama yaşamasına ve kendi seçimini yapmasına da yardımcı olabilir (Lyngs ve ark., 2019; Grüning ve ark., 2023). Bu projede "problemli kullanım" betimleyici bir kavram olarak kullanılmaktadır; yüksek ekran süresi tek başına klinik bağımlılık tanısı değildir. Screen2Sleep AI, tanı veya tedavi sunmak yerine, gece kullanımının olası uyku maliyetini açıklanabilir biçimde görünür kılan ve kullanıcının özerkliğini koruyan bir JITAI tasarlamayı amaçlar.

1.2 Düzenleme

Literatür taraması, Screen2Sleep AI'ın dört temel bileşenine karşılık gelen dört tema etrafında düzenlenmiştir. Her tema projenin bir araştırma sorusunu yanıtlamakta ve bir tasarım kararını desteklemektedir.

Tema	Araştırma sorusu	Projedeki karşılığı
Tema 1 Uyku ölçümü ve kullanım–uyku ilişkisi	Yatma öncesi telefon kullanımı uykuya dalma süresini nasıl etkiler ve bu etki nasıl ölçülür?	Birincil çıktı (uykuya dalma süresi), sabah öz-değerlendirmesi, Health Connect entegrasyonu
Tema 2 Uygulama kullanımı ve oturum süresi tahmini	Başlamış bir oturumun kalan süresi önceden tahmin edilebilir mi?	Model A
Tema 3 Pasif algılama ve kişiselleştirme	Kişiler arası farklar düşünüldüğünde tahmin kişiye nasıl uyarlanabilir?	Model B
Tema 4 Müdahale ve etik	Doğru anda yapılan bir müdahale, kullanıcının özerkliğine saygı göstererek nasıl tasarlanabilir?	Bildirim/uyarı tasarımı, risk yönetimi

Temalar, sistemin işleyiş sırasını izlemektedir: önce neyin ölçüleceği ve neden önemli olduğu (Tema 1), ardından riskin nasıl tahmin edileceği (Tema 2–3), son olarak bu tahmine göre nasıl müdahale edileceği (Tema 4).

1.3 Özet ve Sentez

Tema 1: Uyku ölçümü ve kullanım–uyku ilişkisi (uykuya dalma süresi odaklı)

Screen2Sleep AI'ın birincil çıktısı uykuya dalma süresidir. Bu nedenle bu tema iki soruyu ele almaktadır: yatma öncesi telefon kullanımının uykuya dalma süresini hangi mekanizmalarla etkilediği ve bu sürenin ev ortamında güvenilir biçimde nasıl ölçülebileceği. İncelenen çalışmalar, telefon kullanımı ile uyku arasında tutarlı bir ilişki olduğunu göstermekle birlikte, bu ilişkinin yönü ve büyüklüğü konusunda ayrışmaktadır. Ölçüm tarafında ise giyilebilir cihazların uykuya dalma süresini tek başına güvenilir biçimde ölçemediği görülmektedir.

Makale 1: Carney ve arkadaşları (2012) – The Consensus Sleep Diary: Standardizing prospective sleep self-monitoring

- **Amaç:** Uzman uzlaşısıyla, hasta görüşü alınarak standart bir uyku günlüğü geliştirmek.
- **Örneklem ve büyüklük:** Uykusuzluk uzmanlarından oluşan çalışma grubu ve potansiyel kullanıcılar.
- **Yöntem:** Uzlaşı süreci; temel maddeler "Core" günlüğe, isteğe bağlı maddeler genişletilmiş sürüme alınmıştır.
- **Temel bulgu:** Uyku günlüğü öznel uyku ölçümünde altın standart kabul edilmesine rağmen standart bir formatı yoktu; çalışma bu boşluğu kapatan ilk standart günlüğü sunmaktadır.

- **Sınırlılık:** Öncelikle uykusuzluk araştırması için geliştirilmiştir; uzun süreli kullanımın getirdiği yük test edilmemiştir.
- **Projeye katkısı:** Uygulamadaki sabah öz-değerlendirmesinin maddeleri (yatma saati, uykuya dalma süresi, uyanma sayısı, uyku kalitesi) bu günlükten uyarlanabilir.

Makale 2: Chinoy ve arkadaşları (2021) – Performance of seven consumer sleep-tracking devices compared with polysomnography

- **Amaç:** Güncel tüketici uyku takip cihazlarının performansını aktigrafi ile birlikte polisomnografiye (PSG) karşı test etmek.
- **Örneklem ve büyüklük:** 34 sağlıklı genç yetişkin, laboratuvarda art arda üç gece (biri bölünmüş uyku koşulu).
- **Yöntem:** PSG ile eşzamanlı aktigrafi ve tüketici cihazları; epok bazında uyum analizi.
- **Temel bulgu:** Duyarlılık yüksek (tümü ≥0,93), özgüllük düşük-orta (0,18–0,54); bölünmüş uykulu gecelerde performans düşmüştür.
- **Sınırlılık:** Sağlıklı genç örneklem ve laboratuvar ortamı.
- **Projeye katkısı:** Cihazlar uykuyu iyi, uyanıklığı zayıf tespit etmektedir. Uykuya dalma süresi uyanıklık tespitine dayandığı için giyilebilir veri tek başına yeterli değildir.

Makale 3: Schyvens ve arkadaşları (2025) – A performance validation of six commercial wrist-worn wearable sleep-tracking devices for sleep stage scoring compared to polysomnography

- **Amaç:** Güncel bilek tipi cihazların (Fitbit, Withings, Garmin, Whoop, Apple Watch) PSG'ye karşı performansını değerlendirmek.
- **Örneklem ve büyüklük:** 62 yetişkin (52 erkek, 10 kadın, ortalama yaş 46).
- **Yöntem:** Tek gece PSG ile eşzamanlı 2–4 cihaz.
- **Temel bulgu:** Tüm cihazlar uyku epoklarının %90'ından fazlasını yakalamış, ancak özgüllük %29,39–52,15 aralığında kalmıştır.
- **Sınırlılık:** Erkek ağırlıklı örneklem ve tek gece ölçüm.
- **Projeye katkısı:** Makale 2'deki uyanıklık tespiti sorununun yeni cihaz kuşağında da sürdüğünü göstermektedir.

Makale 4: Cain ve Gradisar (2010) – Electronic media use and sleep in school-aged children and adolescents: A review

- **Amaç:** Elektronik medya kullanımı ile uyku arasındaki ilişkiye dair kanıtları derlemek.
- **Yöntem:** Literatür derlemesi.
- **Temel bulgu:** Ekranın uykuyu etkileme yollarına dair klasik çerçeveyi önermiştir: zaman yer değiştirmesi, içeriğe bağlı uyarılma ve ışık.
- **Sınırlılık:** Çocuk ve ergen örneklemi; akıllı telefonun yaygınlaşmasından önceki dönem.
- **Projeye katkısı:** Bu temadaki diğer çalışmaların mekanizmalarını yorumlamak için kuramsal temel sağlamaktadır.

Makale 5: Hale ve Guan (2015) – Screen time and sleep among school-aged children and adolescents: A systematic literature review

- **Amaç:** Ekran süresi ile uyku çıktıları arasındaki ilişkiyi sistematik olarak güncellemek.
- **Örneklem ve büyüklük:** 1999–2014 arasında yayımlanmış 67 çalışma.
- **Yöntem:** Sistematik literatür taraması.
- **Temel bulgu:** Çalışmaların %90'ında ekran süresi uyku çıktılarıyla olumsuz ilişkili bulunmuştur; özellikle uyku süresi kısalmakta ve zamanlaması gecikmektedir.
- **Sınırlılık:** Nedensellik doğrulanmamıştır; hem ekran süresi hem uyku ölçümünde hata vardır.
- **Projeye katkısı:** Ölçüm hatası eleştirisi, telefon verisinin pasif ve nesnel toplanması kararını gerekçelendirmektedir.

Makale 6: Chang ve arkadaşları (2015) – Evening use of light-emitting eReaders negatively affects sleep, circadian timing, and next-morning alertness

- **Amaç:** Yatmadan önce ışık yayan cihazla okumanın uyku ve sirkadiyen ritim üzerindeki biyolojik etkilerini basılı kitapla karşılaştırmak.
- **Örneklem ve büyüklük:** 12 yetişkin.
- **Yöntem:** Laboratuvarda, katılımcı içi karşılaştırma; melatonin kan örnekleriyle, uyku PSG ile ölçülmüştür.
- **Temel bulgu:** Tablette okuma, uykuya dalma süresini yaklaşık 10 dakika uzatmış, REM uykusunu azaltmış ve ertesi sabah uyanıklığı düşürmüştür.
- **Sınırlılık:** Küçük örneklem, laboratuvar ortamı ve gerçek kullanımdan uzun okuma süresi.
- **Projeye katkısı:** Uykuya dalma süresinin ekran kullanımına duyarlı bir çıktı olduğunu deneysel olarak göstermektedir.

Makale 7: Exelmans ve Van den Bulck (2016) – Bedtime mobile phone use and sleep in adults

- **Amaç:** Yetişkinlerde yatma saatindeki telefon kullanımı ile uyku arasındaki ilişkiyi incelemek.
- **Örneklem ve büyüklük:** 18–94 yaş arası 844 Flaman yetişkin.
- **Yöntem:** Kesitsel anket.
- **Temel bulgu:** Yatakta telefon kullanımı daha geç kalkış, daha yüksek uykusuzluk skoru ve artan yorgunluğu yordamıştır; bu ilişkileri yaş düzenlemiştir.
- **Sınırlılık:** Öz-bildirime dayalı ve kesitsel; nedensellik kurulamaz.
- **Projeye katkısı:** Etkinin kişiden kişiye değiştiğini göstererek Model B'deki kişiselleştirme gereksinimini desteklemektedir.

Makale 8: Christensen ve arkadaşları (2016) – Direct measurements of smartphone screen-time: Relationships with demographics and sleep

- **Amaç:** Akıllı telefon ekran süresini doğrudan ölçmek ve uykuyla ilişkisini test etmek.
- **Örneklem ve büyüklük:** 653 gönüllü yetişkin (ortalama yaş 42).

- **Yöntem:** Ekran süresi uygulama aracılığıyla saatlik olarak ölçülmüş ve 30 günlük pencerelerde hesaplanmıştır; uyku PSQI ile değerlendirilmiştir.
- **Temel bulgu:** Yatma saati ve uyku dönemindeki uzun ekran süresi, daha uzun uykuya dalma süresiyle ilişkili bulunmuştur. Yatmadan önceki saatteki kullanım ise bu ilişkiyi göstermemiştir.
- **Sınırlılık:** Ters yönlü nedensellik mümkündür; kötü uyku ekran süresini artırıyor olabilir.
- **Projeye katkısı:** Telefon verisinin pasif toplanabileceğini göstermekte ve müdahalenin yatağa girdikten sonraki pencereye odaklanması gerektiğini desteklemektedir.

Makale 9: He ve arkadaşları (2020) – Effect of restricting bedtime mobile phone use on sleep, arousal, mood, and working memory: A randomized pilot trial

- **Amaç:** Yatma öncesi telefon kısıtlamasının uyku, uyku öncesi uyarılma, duygu durumu ve çalışma belleği üzerindeki etkisini test etmek.
- **Örneklem ve büyüklük:** 38 üniversite öğrencisi (müdahale n=19, kontrol n=19).
- **Yöntem:** Randomize pilot çalışma; müdahale grubundan yatmadan 30 dakika önce telefonu kullanmamaları istenmiştir. Ölçüm araçları: uyku günlüğü, PSQI, Uyku Öncesi Uyarılma Ölçeği, PANAS.
- **Temel bulgu:** Dört haftalık kısıtlama uykuya dalma süresini ve uyku öncesi uyarılmayı azaltmış, uyku süresini ve kalitesini artırmıştır.
- **Sınırlılık:** Küçük pilot örneklem; ölçümler büyük ölçüde öz-bildirime dayalıdır.
- **Projeye katkısı:** Yatma öncesi müdahalenin uykuya dalma süresini iyileştirebileceğine dair nedensel kanıt sunmaktadır.

Makale 10: Bauducco ve arkadaşları (2024) – A bidirectional model of sleep and technology use: A theoretical review of how much, for whom, and which mechanisms

- **Amaç:** Teknoloji ve uyku ilişkisine dair kuramsal modeli son on yılın kanıtlarıyla güncellemek.
- **Örneklem ve büyüklük:** Kuramsal derleme (örneklem yok).
- **Yöntem:** Önceki mekanizmalara (ışık, uyarılma, gece uyanmaları, uykunun yer değiştirmesi) dair kanıtların değerlendirilmesi.
- **Temel bulgu:** İlişkiye çift yönlü bağlar eklenmiştir. Uyku sorunu teknoloji kullanımından önce gelebilir; teknoloji uyku öncesinde zaman doldurucu veya duygu düzenleme aracı olarak kullanılabilir.
- **Sınırlılık:** Yazarlardan birinin bir uyku uygulaması şirketiyle bağlantısı bulunmaktadır; bu durum çıkar çatışması açısından dikkate alınmalıdır.
- **Projeye katkısı:** Modelin “kötü uyuyan kişi telefona yöneliyor” senaryosunu da hesaba katması gerektiğini göstermektedir.

Tema 1 Sentezi: Çalışmalar, yatma saati civarındaki telefon kullanımının daha uzun uykuya dalma süresiyle ilişkili olduğu konusunda birleşmektedir. Ancak kanıtın çoğu kesitsel ve öz-bildirime dayalıdır; nedensellik yalnızca küçük örneklemli deneysel (Chang ve ark., 2015) ve müdahale (He ve ark., 2020) çalışmalarında görülmektedir. Çalışmalar mekanizmanın ağırlığında ayrışmaktadır: laboratuvar çalışması

belirgin bir ışık etkisi bulurken güncel kuramsal model içerik, uyarılma ve çift yönlülüğü öne çıkarmaktadır (Bauducco ve ark., 2024). Projemiz açısından en belirleyici bulgu, riskin yatağa girdikten sonraki dönemde yoğunlaşmasıdır (Christensen ve ark., 2016); bu bulgu Model A'nın yatma sonrası oturum süresine odaklanmasını desteklemektedir. Ölçüm tarafında giyilebilir cihazlar uykuyu iyi, uyanıklığı zayıf tespit ettiğinden (Chinoy ve ark., 2021; Schyvens ve ark., 2025), uykuya dalma süresi için standart bir sabah öz-değerlendirmesi (Carney ve ark., 2012) birincil ölçüm olarak kullanılmalı, Health Connect verisi ise mevcutsa destekleyici olarak eklenmelidir.

Tema 2: Uygulama kullanımı ve oturum süresi tahmini

Screen2Sleep AI'ın Model A bileşeni, devam eden bir uygulama oturumunun ne kadar daha süreceğini tahmin etmeyi amaçlamaktadır. Bu nedenle bir sonraki kullanılacak uygulamayı tahmin etmek, oturumun toplam süresini tahmin etmek ve başlamış bir oturumun kalan süresini tahmin etmek birbirinden ayrılmalıdır. İncelenen çalışmalar, uygulama kullanımının bağlama ve kişisel geçmişe göre modellenmesini desteklemektedir; ancak sonuçlarının devam eden gece oturumlarına aktarılabilirliği ayrıca değerlendirilmelidir.

Makale 1: Aliannejadi ve arkadaşları (2021) – Context-aware target apps selection and recommendation for enhancing personal mobile assistants

- **Amaç:** Mobil asistanlarda arama için uygun uygulamayı seçmek ve kullanıcının sonraki açacağı uygulamaları bağlam bilgisiyle tahmin etmek.
- **Örneklem ve büyüklük:** Çalışmanın LSApp veri seti 292 kullanıcı, 599.635 uygulama kullanım kaydı ve 87 farklı uygulama içermektedir.
- **Yöntem:** Android tabanlı uSearch aracılığıyla kullanım verileri toplanmış; uygulama sırası, zamansal bağlam ve kişisel davranışları kullanan sinir ağı modelleri karşılaştırılmıştır.
- **Temel bulgu:** Önerilen bağlam farkındalıklı modeller, uygulama önerisi görevinde karşılaştırılan temel yöntemlerden daha iyi sonuç vermiştir.
- **Sınırlılık:** Çalışma doğrudan kalan oturum süresini tahmin etmemektedir. Ayrıca veri hazırlığında kısa aralıklarla tekrarlanan kayıtların birleştirilmesi, süre analizi açısından ayrıca incelenmelidir.
- **Projeye katkısı:** Model A'da uygulama geçmişi, saat ve kişisel kullanım alışkanlıklarının kullanılmasını destekler. LSApp, oturum oluşturma kuralları doğrulandıktan sonra süre tahmini için değerlendirilebilir; makalenin uygulama önerisi başarısı, kalan süre tahmininin başarısı olarak yorumlanamaz.

Makale 2: Tian, Zhou ve Pelleg (2021) – What and how long: Prediction of mobile app engagement

- **Amaç:** Kullanıcının hangi uygulamayı kullanacağını ve uygulamada ne kadar kalacağını birlikte tahmin etmek.
- **Örneklem ve büyüklük:** ABD'de bir mobil reklam şirketi üzerinden, bir haftada 12 binden fazla kullanıcıya ait yaklaşık 1,3 milyon kullanım kaydı incelenmiştir.

- **Yöntem:** Kullanıcı özellikleri, saat ve gün bilgisi, kısa dönem kullanım bağlamı ve uzun dönem alışkanlıkları analiz edilmiştir. Sonraki uygulama ile kullanım yoğunluğu düzeyini birlikte tahmin eden yöntemler karşılaştırılmıştır.
- **Temel bulgu:** Geçmiş kullanım eğilimleri ve zamansal örüntüler tahminde yararlı bulunmuş; önerilen boosting tabanlı ortak tahmin yaklaşımı karşılaştırılan yöntemlere üstünlük sağlamıştır.
- **Sınırlılık:** Gözlem dönemi kısadır ve veri toplama altyapısı bütün uygulamaları kapsamaz. Ayrıca süre, kullanım yoğunluğu sınıflarıyla temsil edildiği için sonuçlar doğrudan dakika cinsinden kalan süre tahmini değildir.
- **Projeye katkısı:** Model A'nın yalnızca uygulama adına dayanmaması; kişinin geçmiş oturumlarını ve zaman bağlamını da kullanması gerektiğini destekler.

Makale 3: Vasiloudis ve arkadaşları (2017) – Predicting session length in media streaming

- **Amaç:** Bir müzik hizmetindeki oturum sürelerini analiz etmek ve başlangıçta bilinen bilgilerle toplam oturum süresini tahmin etmek.
- **Örneklem ve büyüklük:** Şubat–Nisan 2016 dönemine ait 4.030.755 oturum incelenmiştir. Tahmin deneylerinde, en az 20 oturumu bulunan kullanıcıların 3.563.544 oturumu kullanılmıştır.
- **Yöntem:** Süre dağılımları Weibull yaklaşımıyla analiz edilmiş; farklı kayıp fonksiyonlarına sahip gradyan artırmalı ağaçlar, kişisel ortalama süre referansıyla karşılaştırılmıştır.
- **Temel bulgu:** En iyi yöntem değerlendirme ölçütüne göre değişmiştir. Topluluk modeli medyan mutlak hatada, Gamma amaç fonksiyonlu topluluk modeli ise normalize RMSE'de daha başarılı olmuştur.
- **Sınırlılık:** Müzik dinleme, ekranla aktif etkileşim gerektirmeyebilir. Ayrıca tahmin oturum başlangıcında yapılmıştır; devam eden oturumun kalan süresi değerlendirilmemiştir.
- **Projeye katkısı:** Süre dağılımına uygun yöntem ve birden fazla hata ölçütü seçimini destekler. Çalışmadaki sağkalım analizi dağılım incelemesinde, ağaç modelleri ise süre tahmininde kullanılmıştır; bunlar aynı işlem olarak sunulmamalıdır.

Tema 2 Sentezi: İncelenen çalışmalar, kullanım geçmişinin ve bağlam bilgisinin davranış tahminine katkı sağladığı konusunda birleşmektedir. Bununla birlikte tahmin hedefleri farklıdır: Aliannejadi ve arkadaşları uygulama seçimine, Tian ve arkadaşları uygulama ve kullanım yoğunluğuna, Vasiloudis ve arkadaşları toplam oturum süresine odaklanmaktadır. Screen2Sleep AI için bu literatürden çıkarılan tasarım kararı, devam eden oturumun geçen süresini de dikkate alan ve belirsizlik sunan bir Model A geliştirmektir. Bu yaklaşımın gece kullanımındaki başarısı, kişisel referans yöntemlerle karşılaştırılarak ayrıca sınanmalıdır.

Tema 3: Pasif algılama, uyku tahmini ve kişiselleştirme

Makale 1: GLOBEM Çalışması (Xu ve ark., 2022)

- **Künye:** Xu, X., Liu, X., Zhang, H., Wang, W., Nepal, S., Sefidgar, Y., Seo, W., Kuehn, K. S., Huckins, J. F., Morris, M. E., Nurius, P. S., Riskin, E. A., Patel, S., Althoff, T., Campbell, A., Dey, A. K., & Mankoff, J. (2022). GLOBEM: Cross-Dataset Generalization of Longitudinal Human Behavior

Modeling. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 6(4), Article 190, 1–34. https://doi.org/10.1145/3569485

- **Amaç:** Akıllı telefonlar ve giyilebilir cihazlardan elde edilen uzun süreli pasif sensör verileriyle eğitilen davranış modellerinin (depresyon tespiti senaryosunda) farklı veri setleri, kurumlar ve yıllar arasındaki genellenebilirliğini (*cross-dataset generalizability*) sistematik olarak test etmek ve açık kaynaklı bir kıyaslama (*benchmark*) platformu sunmak.
- **Örneklem ve büyüklük:** ABD'deki iki farklı R-1 üniversitesinden 2018 ve 2019 bahar dönemlerinde (her biri 10 haftalık çeyrek dönem) toplanan 4 veri seti (DS1, DS2, DS3, DS4). Toplam 618 kişi-yıl (*person-years*), örtüşen kullanıcılar çıkarıldığında 534 benzersiz lisans öğrencisi (DS1: 155, DS2: 218, DS3: 93, DS4: 152). Katılımcı profili kadın ağırlıklıdır (DS1'de 107 kadın, 48 erkek).
- **Yöntem:** AWARE altyapısıyla pasif telefon logları (konum, ekran durumu), Fitbit ve telefon sensörleriyle fiziksel aktivite/uyku verileri toplanmıştır. RAPIDS platformu ile ortak özellikler (konum, ekran, aktivite, uyku) 4 günlük zaman dilimi (sabah, öğle, akşam, gece), günlük ve 2 haftalık pencerelerle çıkarılmış ve 28 günlük matrisler (28 × özellik sayısı) oluşturulmuştur. Literatürdeki 9 klasik algoritma, derin öğrenme tabanlı 8 alan genelleme yöntemi ve önerilen 2 yeni yöntem (Clustering ve Reorder), *leave-one-dataset-out* ve kurumlar arası test senaryolarıyla karşılaştırılmıştır.
- **Temel bulgu:** Tek bir veri setinde eğitilen modeller yeni veri setlerine uygulandığında dramatik bir düşüş göstermiş; orijinal literatür sonuçları ile test sonuçları arasında ortalama %18,9 ± 9,7 performans kaybı gözlenmiştir. Bilgisayarlı görü/NLP'den uyarlanan alan genelleme modelleri %50 taban çizgisini neredeyse geçememiştir (en iyi ROC AUC %52,3). Zamansal sürekliliği öğrenen Reorder yöntemi %57,5 ROC AUC ve %55,2 dengeli doğrulukla en iyi sonucu vermiştir ($p < 0,05$). Bireyi tanıma görevinde (*Distinguish-The-Person*) 10 veri noktasıyla %87,4 doğruluğa ulaşılması, alan genellemesindeki asıl zorluğun popülasyon farkından ziyade bireyler arası yüksek varyans olduğunu kanıtlamıştır.
- **Sınırlılık:** Reorder'ın ulaştığı %57,5 ROC AUC pratik saha dağıtımı için halen düşüktür. Yalnızca üniversite öğrencilerini kapsar. Eksik veri oranı %7,3 ± 2,3 seviyesindedir ve medyan ile doldurulmuştur.
- **Projeye katkısı:** Screen2Sleep AI mimarisinde neden popülasyon genelinde sabit bir kural işletilemeyeceğinin doğrudan kanıtıdır. Bireyler arası devasa varyans, sistemin başlangıçta açık veri setiyle başlasa bile hızla bireyin geçmişine uyarlanan Model B (Kişiselleştirme) yaklaşımını benimsemesini zorunlu kılar.

Makale 2: StudentLife Çalışması (Wang ve ark., 2014)

- **Künye:** Wang, R., Chen, F., Chen, Z., Li, T., Harari, G., Tignor, S., Zhou, X., Ben-Zeev, D., & Campbell, A. T. (2014). StudentLife: Assessing Mental Health, Academic Performance and Behavioral Trends of College Students using Smartphones. *Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '14)*, 3–14. https://doi.org/10.1145/2632048.2632054

- **Amaç:** Üniversite öğrencilerinin iş yükü, stres, uyku, fiziksel aktivite, sosyallik ve akademik başarılarını; akıllı telefon sensörleri üzerinden sürekli ve pasif algılama (*continuous passive sensing*) ile ekolojik anlık değerlendirmeleri (*EMA*) birleştirerek otomatik analiz etmek.
- **Örneklem ve büyüklük:** Dartmouth College'da 2013 bahar döneminde (10 hafta) CS65 dersini alan öğrencilerden çalışmayı tamamlayan 48 öğrenci (30 lisans, 18 lisansüstü; 10 kadın, 38 erkek).
- **Yöntem:** Katılımcılara Android telefonlar verilerek 52,6 GB veri toplanmıştır. Telefon kilit durumu (ekran açık/kapalı), ivmeölçer, ışık sensörü ve mikrofondan gelen ses özellikleri birleştirilerek doğrusal model ile uyku çıkarımı yapılmıştır. Günlük yaşam 3 dilime bölünmüştür: Gün (09:00–18:00), Akşam (18:00–24:00) ve Gece (24:00–09:00). Toplam 35,295 EMA yanıtı ve pre-post PHQ-9 (depresyon) ölçekleri toplanmıştır.
- **Temel bulgu:** Akıllı telefon ekran kilit logları, hareket ve ses kombinasyonu ile uyku süresi ±32 dakika hata payıyla; uykuya dalma anı (*bedtime/sleep onset*) ise Jawbone UP bileklikleriyle kıyaslandığında %95 oranında ±25 dakika doğrulukla tespit edilmiştir. Otomatik algılanan uyku süresi ile PHQ-9 depresyon skoru arasında negatif korelasyon ($r = -0,382$; $p = 0,020$), stres (PSS) ile negatif korelasyon ($r = -0,355$; $p = 0,024$) saptanmıştır. Öğrencilerin büyük çoğunluğunun gece 24:00–04:00 arasında yatağa girdiği ve sınav dönemlerinde uykunun dramatik şekilde dip yaptığı görülmüştür.
- **Sınırlılık:** Küçük örneklem boyutu (N = 48) ve tek bir teknik ders grubuyla sınırlı olması (%79 erkek). Katılımcıların %77'si (37/48) ikinci bir cihaz taşımak zorunda kalmıştır.
- **Projeye katkısı:** Giyilebilir cihaz olmasa dahi akıllı telefonun ekran kilit açma/kapama logları ve şarj döngüsüyle uyku penceresi ve uykuya dalma anının (±25 dk) güvenilir biçimde kestirilebileceğini doğrular. Akşam ve gece dilimi ayrımının önemini ortaya koyar.

Makale 3: SNAPSHOT Çalışması (Sano ve ark., 2018)

- **Künye:** Sano, A., Taylor, S., McHill, A. W., Phillips, A. J., Barger, L. K., Klerman, E., & Picard, R. (2018). Identifying Objective Physiological Markers and Modifiable Behaviors for Self-Reported Stress and Mental Health Status Using Wearable Sensors and Mobile Phones: Observational Study. *Journal of Medical Internet Research*, 20(6), e210. https://doi.org/10.2196/jmir.9410
- **Amaç:** Giyilebilir sensörler ve akıllı telefonlarla 24/7 toplanan nesnel fizyolojik veriler ile değiştirilebilir davranışsal örüntülerin (ekran süresi, uyku düzeni), yüksek stres (PSS) ve düşük zihinsel sağlık (SF-12 MCS) durumlarını sınıflandırmadaki ayırt ediciliğini belirlemek.
- **Örneklem ve büyüklük:** MIT'de 5 yarıyıl boyunca takip edilen 201 lisans öğrencisi (18–25 yaş; 129 erkek, 72 kadın). Toplam 145,000 saatten fazla sürekli veri ve 6,077 gün elektronik günlük.
- **Yöntem:** Q-sensor (deri iletkenliği - SC, cilt sıcaklığı - ST), Motion Logger ve Funf tabanlı Android uygulamasıyla ekran açık kalma süreleri (*screen-on*) toplanmıştır. Veriler 4 zaman dilimine ayrılmıştır (Gündüz, Akşam 18–24, Gece Yarısı 00–03, Uyku). SVM (RBF) ve LASSO modelleri *leave-one-cohort-out* yöntemiyle değerlendirilmiştir.
- **Temel bulgu:** Değiştirilebilir davranış özellikleri (şekerlemeler, çalışma süresi ve telefon ekranı açık kalma süresi) stresi %73,5, zihinsel sağlığı %79 doğrulukla sınıflandırmıştır. Özellikle gece

yarısı 00:00–03:00 arasındaki ekran etkileşimleri, zihinsel sağlık durumunu ayırt etmede en sık seçilen özelliklerden biri olmuştur. Gruplar arasında ortalama uyku süresi bakımından anlamlı fark bulunamazken (p = 0,09 ve p = 0,72), gece yarısı ekran kullanımı ve uyku düzensizliği belirleyici olmuştur.

- **Sınırlılık:** Katılımcıların %64'ü erkektir. Sadece Android kullanıcılarını içerir (seçim yanlılığı riski). Sosyal olarak bağlantılı öğrenci ağlarından toplandığı için davranış bulaşması mevcuttur.
- **Projeye katkısı:** Projenin temel hipotezini doğrular: Sorun sadece toplam uyku süresi değil, yatma penceresinde (özellikle gece yarısı) telefonda geçirilen aktif ekrandır. Model B'nin tahmin edeceği "ek uykuya dalma süresi"nin gecikmiş ekran kullanımıyla doğrudan tetiklendiğini kanıtlar.

Tema 3 Sentezi: İncelenen çalışmalar (Wang ve ark., 2014; Sano ve ark., 2018; Xu ve ark., 2022), akıllı telefon sensörlerinden ve kilit açma loglarından elde edilen pasif verilerin, uyku hijyeni ve davranışsal ritimleri objektif biçimde izlemede güvenilir bir zemin sunduğunda birleşmektedir. Wang ve ark. (2014) telefon kilit ve şarj loglarıyla uykuya dalma anının ±25 dakika hata payıyla saptanabileceğini gösterirken, Sano ve ark. (2018) ortalama uyku süresinden ziyade özellikle 00:00–03:00 arasındaki gece ekran etkileşimlerinin belirleyici olduğunu kanıtlamıştır. Ancak GLOBEM (Xu ve ark., 2022) bulguları, literatürdeki en kritik tasarım sınırlılığını açığa çıkarmaktadır: Popülasyon düzeyinde eğitilen statik modeller yeni kullanıcılarda ortalama %18,9 ± 9,7 performans kaybı yaşamakta, bireyi tanıma doğruluğu ise %87,4'e ulaşmaktadır. Bu ayrışma, Screen2Sleep AI mimarisinde herkes için tek bir eşik değeri koyan statik bir kural yerine; başlangıçta açık veri setiyle eğitilen, ardından kullanıcının Health Connect / UsageStats verileri geldikçe bireysel ortalamaya adapte olan Model B (Kişiselleştirilmiş Karma Etkili / Bayesçi Model) kararını doğrudan desteklemektedir.

Tema 4: Anlık müdahaleler (JITAI), dijital öz-denetim ve etik

Tema 4, tahmin üretmekten davranışsal desteğe geçişi ele alır. JITAI çerçevesi, dijital öz-denetim araçları, açıklanabilir müdahaleler, kullanıcı özerkliği ve etik riskler birlikte değerlendirilmiştir.

Makale 1: Nahum-Shani ve arkadaşları (2018): Just-in-Time Adaptive Interventions (JITAIs) in Mobile Health: Key Components and Design Principles for Ongoing Health Behavior Support

- **Amaç:** JITAI yaklaşımının temel bileşenlerini ve tasarım ilkelerini sistematik biçimde tanımlamak.
- **Örneklem ve büyüklük:** Yeni katılımcı toplayan bir deney değildir; yöntemsel ve kuramsal bir makaledir, bu nedenle tek bir örneklem büyüklüğü yoktur.
- **Yöntem:** Sağlık davranışı teorileri ve önceki mobil müdahale örneklerinden hareketle karar anı, uyarlama değişkenleri, müdahale seçenekleri, karar kuralları ve yakın/uzak sonuç kavramları yapılandırılmıştır.
- **Temel bulgu:** Etkili bir JITAI, yalnızca müdahale içeriğini değil, ne zaman müdahale edileceğini ve kişinin o anda müdahaleye açık olup olmadığını da dikkate almalıdır.
- **Sınırlılık:** Belirli bir akıllı telefon veya uyku uygulamasının klinik etkinliğini kanıtlayan saha deneyi değildir.

- **Projeye katkısı:** Screen2Sleep AI için karar anı, uygunluk durumu, uyarlama değişkenleri, müdahale seçenekleri ve sonuçların açık biçimde tanımlanmasını sağlar.

Makale 2: Lyngs ve arkadaşları (2019): Self-Control in Cyberspace: Applying Dual Systems Theory to a Review of Digital Self-Control Tools

- **Amaç:** Dijital öz-denetim araçlarının hangi psikolojik mekanizmalar üzerinden çalıştığını sınıflandırmak.
- **Örneklem ve büyüklük:** 367 dijital öz-denetim aracı/uygulama ve tarayıcı uzantısı incelenmiştir; insan katılımcılı kontrollü etkinlik deneyi değildir.
- **Yöntem:** Uygulama mağazaları ve araç özellikleri, ikili süreç ve öz-denetim kuramları çerçevesinde sistematik olarak analiz edilmiştir.
- **Temel bulgu:** Erişim engelleme, zaman sınırı, davranışı görünür kılma ve sürtünme yaratma gibi stratejiler farklı öz-denetim mekanizmalarına dayanır; tek seçenek sert bloklama değildir.
- **Sınırlılık:** Araç özelliklerinin sınıflandırılması, uzun vadeli davranışsal veya sağlık etkisini tek başına göstermez; ürün özellikleri zamanla değişebilir.
- **Projeye katkısı:** Kullanıcıyı zorla engellemek yerine kısa, açıklanabilir ve geri alınabilir bir müdahale tasarımının literatürdeki yerini gerekçelendirir.

Makale 3: Grüning, Riedel ve Lorenz-Spreen (2023): Directing Smartphone Use Through the Self-Nudge App one sec

- **Amaç:** Hedef uygulama açılışından önce kısa bir öz-dürtme müdahalesinin otomatik/alışkanlık temelli kullanımı azaltıp azaltmadığını test etmek.
- **Örneklem ve büyüklük:** Altı haftalık saha deneyinde 280 katılımcının davranışsal verileri analiz edilmiştir; makale ayrıca kontrollü deney bileşeni içerir.
- **Yöntem:** Hedef uygulama açılırken kısa bir bekleme, düşünme mesajı ve açılışı iptal etme seçeneği sunulmuştur; ön-son anketler ve gerçek kullanım davranışı incelenmiştir.
- **Temel bulgu:** Katılımcılar hedef uygulama açma girişimlerinin ortalama %36'sında müdahale sonrası açılışı iptal etmiş, altı hafta içinde hedef uygulamaları açma girişimleri ilk haftaya göre %37 azalmış ve gerçekleşen açılışlarda toplam azalma %57'ye ulaşmıştır.
- **Sınırlılık:** Uygulamayı gönüllü olarak kuran kişilerde seçilim yanlılığı olabilir; çalışma uykuya dalma süresi veya uyku sağlığı çıktısını doğrudan ölçmemiştir.
- **Projeye katkısı:** Kısa bir karar eşiği ve açık bir "vazgeç" seçeneğinin kullanıcı özerkliğini koruyarak davranışı değiştirebileceğini gösterir.

Makale 4: Xu ve arkadaşları (2022): TypeOut: Leveraging Just-in-Time Self-Affirmation for Smartphone Overuse Reduction

- **Amaç:** Kısa yazma görevi ile öz-olumlama içeriğini birleştiren JITAI yaklaşımının akıllı telefon aşırı kullanımını azaltıp azaltmadığını test etmek.
- **Örneklem ve büyüklük:** 54 kişi, 10 haftalık katılımcı-içi saha deneyi.

- **Yöntem:** TypeOut, yalnızca öz-olumlama içeriği ve yalnızca anlam taşımayan yazma görevi içeren iki karşılaştırma koşuluyla değerlendirilmiştir.
- **Temel bulgu:** Yazarlar kendi deney koşullarında uygulama kullanımında %50'nin üzerinde, açma sıklığı ve kullanım süresinde %25'in üzerinde azalmalar bildirmiştir.
- **Sınırlılık:** Yazma yükü ve örneklem bağlamı genellenebilirliği sınırlar; uyku sonuçları çalışmanın birincil çıktısı değildir.
- **Projeye katkısı:** Kısa bilişsel duraklamaların yararlı olabileceğini, ancak müdahale yükünün ve bırakma oranının ayrıca ölçülmesi gerektiğini gösterir.

Makale 5: Orzikulova ve arkadaşları (2024): Time2Stop: Adaptive and Explainable Human-AI Loop for Smartphone Overuse Intervention

- **Amaç:** Makine öğrenmesiyle uygun müdahale zamanını belirleyen, açıklama sunan ve kullanıcı geri bildirimiyle kendini uyarlayan bir JITAI geliştirmek.
- **Örneklem ve büyüklük:** 71 katılımcı, 8 haftalık saha deneyi.
- **Yöntem:** Uyarlanabilir müdahale zamanlaması ve açıklama bileşenleri, temel yöntemlerle ve kullanıcı geri bildirimiyle karşılaştırılmıştır.
- **Temel bulgu:** Uyarlanabilir modeller müdahale zamanı doğruluğunda göreli olarak %32,8'den fazla ve alıcılıkta %8'den fazla iyileşme göstermiş; açıklamalar doğruluk ve alıcılığı daha da artırmış, uygulama ziyaret sıklığı %7,0–8,9 azalmıştır.
- **Sınırlılık:** Uykuya dalma süresi veya "çalınan uyku" doğrudan değerlendirilmemiştir; sekiz haftalık çalışma uzun vadeli etkiyi garanti etmez.
- **Projeye katkısı:** Müdahale zamanlaması, açıklanabilirlik ve kullanıcı geri bildirimini aynı döngüde birleştirmek için doğrudan örnek sağlar. Screen2Sleep'in yenilik iddiası yalnızca açıklanabilir veya kişiselleştirilmiş uyarı vermek değildir.

Makale 6: Baron ve arkadaşları (2017): Orthosomnia: Are Some Patients Taking the Quantified Self Too Far?

- **Amaç:** Uyku izleyici verilerine aşırı odaklanmanın bazı kişilerde yaratabileceği klinik sorunları tanımlamak.
- **Örneklem ve büyüklük:** Klinik olgu raporları; toplum düzeyinde temsili bir örneklem değildir.
- **Yöntem:** Uyku kliniğine başvuran hastalara ilişkin klinik gözlemler ve olgu anlatımı.
- **Temel bulgu:** Bazı kullanıcılar uyku izleyici skorlarını "mükemmel" hale getirmeye çalışırken uyku hakkında kaygı ve işlevsiz davranış geliştirebilir.
- **Sınırlılık:** Yaygınlık tahmini veya nedensel etki büyüklüğü vermez.
- **Projeye katkısı:** Screen2Sleep'in tehditkâr, kesin, moralize eden veya sürekli puan üreten bir tasarımdan kaçınması gerektiğini destekler.

Tema 4 Sentezi: JITAI literatürü doğru zaman ve uygunluk kavramlarını tanımlarken (Nahum-Shani ve ark., 2018), dijital öz-denetim çalışmaları müdahalenin bloklama dışındaki biçimlerini gösterir (Lyngs ve ark., 2019). one sec ve TypeOut, davranışın önüne küçük bir karar eşiği koymanın kullanım davranışını

değiştirebileceğine ilişkin saha kanıtı sunarken; Time2Stop, müdahale zamanlamasının ve açıklamanın kullanıcı alıcılığı açısından ayrıca önemli olduğunu göstermektedir. Buna karşılık bu çalışmaların temel çıktıları uygulama kullanımıdır; Screen2Sleep'in öngördüğü uykuya dalma iyileşmesi bu çalışmalardan doğrudan çıkarılamaz. Baron ve arkadaşlarının klinik gözlemi de kişisel uyku tahminlerinin kaygı üretmemesi gerektiğini vurgular. Bu nedenle Screen2Sleep AI'ın tasarım kararı, "tahmini kalan oturum süresi + belirsizlikli uyku etkisi + kapatılabilir kısa destek" zincirini, gerçek kullanıcı pilotunda hem davranış hem uyku sonuçlarıyla sınamaktır.

1.4 Araştırma Boşluğu ve Sonuç

Literatür taramasındaki dört tema birlikte değerlendirildiğinde, Screen2Sleep AI'ın doldurmayı hedeflediği beş araştırma boşluğu öne çıkmaktadır.

Ölçüm boşluğu. Telefon kullanımı ile uyku arasındaki ilişkiyi inceleyen çalışmaların çoğu, her iki değişkeni de öz-bildirimle ölçmektedir (Hale & Guan, 2015). Telefon kullanımını nesnel olarak ölçen çalışmalar ise uykuyu yine anketle değerlendirmektedir (Christensen ve ark., 2016). Giyilebilir cihazlar uyanıklığı zayıf tespit ettiğinden (Chinoy ve ark., 2021; Schyvens ve ark., 2025), uykuya dalma süresini tek başına güvenilir ölçemezler. Telefonun pasif verisini standart bir sabah öz-değerlendirmesiyle ve mevcutsa giyilebilir veriyle aynı sistemde birleştiren yaklaşımlar sınırlıdır.

Zamanlama boşluğu. Uyku literatürü çoğunlukla günlük toplam ekran süresine odaklanmaktadır. Oysa nesnel veriler riskin yatağa girdikten sonraki dönemde yoğunlaştığını göstermektedir (Christensen ve ark., 2016). Oturum süresini tahmin eden çalışmalar (Aliannejadi ve ark., 2021; Tian ve ark., 2021; Vasiloudis ve ark., 2017) ise bu tahmini uyku bağlamında değil, uygulama önerisi gibi amaçlarla kullanmıştır.

Kişiselleştirme boşluğu. Telefon kullanımının uyku üzerindeki etkisi yaş gibi bireysel özelliklere göre değişmektedir (Exelmans & Van den Bulck, 2016). Buna rağmen mevcut müdahaleler herkese aynı kuralı uygulamaktadır (He ve ark., 2020). Pasif algılama çalışmaları kişiler arası farkların yüksek olduğunu ve popülasyon düzeyinde eğitilen modellerin yeni kullanıcılara zayıf genellendiğini gösterse de (Xu ve ark., 2022), bu bulgu uyku odaklı müdahalelere henüz yeterince aktarılmamıştır.

Müdahale boşluğu. Yatma öncesi müdahalelere dair kanıt, küçük örneklemli ve katı kısıtlamaya dayalı çalışmalardan gelmektedir (He ve ark., 2020). Uyku sorunlarının da telefon kullanımına yol açabildiği düşünüldüğünde (Bauducco ve ark., 2024), yasaklamak yerine kullanıcıyı doğru anda uyaran ve seçimi ona bırakan yaklaşımlara ihtiyaç vardır.

Nedensellik boşluğu. Kanıtın büyük kısmı kesitseldir; deneysel çalışmalar ya laboratuvar ortamında (Chang ve ark., 2015) ya da küçük örneklemlerle (He ve ark., 2020) yürütülmüştür. Gerçek yaşamda, gece gece toplanan uzunlamasına veriyle telefon kullanımının uykuya dalma süresini nasıl etkilediğini inceleyen çalışmalar azdır.

Sonuç. Literatür, yatma saati civarındaki telefon kullanımının uykuya dalma süresini uzatabileceğini tutarlı biçimde göstermektedir. Ancak bu ilişki kişiden kişiye değişmekte ve çift yönlü işleyebilmektedir. Bu bulgular Screen2Sleep AI'ın tasarımını üç noktada desteklemektedir: (1) birincil çıktı olarak uykuya dalma süresinin seçilmesi ve sabah öz-değerlendirmesi ile Health Connect verisinin birlikte kullanılması,

(2) toplam ekran süresi yerine yatma sonrası oturumun kalan süresinin tahmin edilmesi (Model A) ve bu tahminin kişiye uyarlanması (Model B), (3) müdahalenin kısıtlama yerine doğru anda ve kullanıcının özerkliğini koruyarak sunulması (Tema 4). Literatürde nesnel telefon verisi, kişiselleştirilmiş tahmin ve anlık müdahaleyi tek bir sistemde birleştirip uyku çıktısıyla değerlendiren bir çalışmaya rastlanmamıştır; Screen2Sleep AI bu boşluğu doldurmayı amaçlamaktadır.

1.5 Kaynakça

Aşağıdaki kaynakça APA 7 biçiminde birleştirilmiştir.

Aliannejadi, M., Zamani, H., Crestani, F., & Croft, W. B. (2021). Context-aware target apps selection and recommendation for enhancing personal mobile assistants. ACM Transactions on Information Systems, 39(3), Article 29. https://doi.org/10.1145/3447678

Baron, K. G., Abbott, S., Jao, N., Manalo, N., & Mullen, R. (2017). Orthosomnia: Are some patients taking the quantified self too far? Journal of Clinical Sleep Medicine, 13(2), 351–354. https://doi.org/10.5664/jcsm.6472

Bauducco, S., Pillion, M., Bartel, K., Reynolds, C., Kahn, M., & Gradisar, M. (2024). A bidirectional model of sleep and technology use: A theoretical review of how much, for whom, and which mechanisms. Sleep Medicine Reviews, 76, 101933. https://doi.org/10.1016/j.smrv.2024.101933

Cain, N., & Gradisar, M. (2010). Electronic media use and sleep in school-aged children and adolescents: A review. Sleep Medicine, 11(8), 735–742. https://doi.org/10.1016/j.sleep.2010.02.006

Carney, C. E., Buysse, D. J., Ancoli-Israel, S., Edinger, J. D., Krystal, A. D., Lichstein, K. L., & Morin, C. M. (2012). The Consensus Sleep Diary: Standardizing prospective sleep self-monitoring. Sleep, 35(2), 287–302. https://doi.org/10.5665/sleep.1642

Chang, A.-M., Aeschbach, D., Duffy, J. F., & Czeisler, C. A. (2015). Evening use of light-emitting eReaders negatively affects sleep, circadian timing, and next-morning alertness. Proceedings of the National Academy of Sciences, 112(4), 1232–1237. https://doi.org/10.1073/pnas.1418490112

Chinoy, E. D., Cuellar, J. A., Huwa, K. E., Jameson, J. T., Watson, C. H., Bessman, S. C., Hirsch, D. A., Cooper, A. D., Drummond, S. P. A., & Markwald, R. R. (2021). Performance of seven consumer sleep-tracking devices compared with polysomnography. Sleep, 44(5), zsaa291. https://doi.org/10.1093/sleep/zsaa291

Christensen, M. A., Bettencourt, L., Kaye, L., Moturu, S. T., Nguyen, K. T., Olgin, J. E., Pletcher, M. J., & Marcus, G. M. (2016). Direct measurements of smartphone screen-time: Relationships with demographics and sleep. PLOS ONE, 11(11), e0165331. https://doi.org/10.1371/journal.pone.0165331

Exelmans, L., & Van den Bulck, J. (2016). Bedtime mobile phone use and sleep in adults. Social Science & Medicine, 148, 93–101. https://doi.org/10.1016/j.socscimed.2015.11.037

Grüning, D. J., Riedel, F., & Lorenz-Spreen, P. (2023). Directing smartphone use through the self-nudge app one sec. Proceedings of the National Academy of Sciences, 120(8), e2213114120. https://doi.org/10.1073/pnas.2213114120

Hale, L., & Guan, S. (2015). Screen time and sleep among school-aged children and adolescents: A systematic literature review. Sleep Medicine Reviews, 21, 50–58. https://doi.org/10.1016/j.smrv.2014.07.007

He, J.-W., Tu, Z.-H., Xiao, L., Su, T., & Tang, Y.-X. (2020). Effect of restricting bedtime mobile phone use on sleep, arousal, mood, and working memory: A randomized pilot trial. PLOS ONE, 15(2), e0228756. https://doi.org/10.1371/journal.pone.0228756

Lyngs, U., Lukoff, K., Slovak, P., Binns, R., Slack, A., Inzlicht, M., Van Kleek, M., & Shadbolt, N. (2019). Self-control in cyberspace: Applying dual systems theory to a review of digital self-control tools. Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems, Article 131, 1–18. https://doi.org/10.1145/3290605.3300361

Nahum-Shani, I., Smith, S. N., Spring, B. J., Collins, L. M., Witkiewitz, K., Tewari, A., & Murphy, S. A. (2018). Just-in-Time Adaptive Interventions (JITAIs) in mobile health: Key components and design principles for ongoing health behavior support. Annals of Behavioral Medicine, 52(6), 446–462. https://doi.org/10.1007/s12160-016-9830-8

Orzikulova, A., Xiao, H., Li, Z., Yan, Y., et al. (2024). Time2Stop: Adaptive and explainable human-AI loop for smartphone overuse intervention. Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3613904.3642747

Sano, A., Taylor, S., McHill, A. W., Phillips, A. J., Barger, L. K., Klerman, E., & Picard, R. (2018). Identifying objective physiological markers and modifiable behaviors for self-reported stress and mental health status using wearable sensors and mobile phones: Observational study. Journal of Medical Internet Research, 20(6), e210. https://doi.org/10.2196/jmir.9410

Schyvens, A.-M., Peters, B., Van Oost, N. C., Aerts, J.-M., Masci, F., Neven, A., Dirix, H., Wets, G., Ross, V., & Verbraecken, J. (2025). A performance validation of six commercial wrist-worn wearable sleep-tracking devices for sleep stage scoring compared to polysomnography. Sleep Advances, 6(2), zpaf021. https://doi.org/10.1093/sleepadvances/zpaf021

Tian, Y., Zhou, K., & Pelleg, D. (2021). What and how long: Prediction of mobile app engagement [Ön baskı]. arXiv. https://arxiv.org/abs/2106.01490

Vasiloudis, T., Vahabi, H., Kravitz, R., & Rashkov, V. (2017). Predicting session length in media streaming. Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval. https://doi.org/10.1145/3077136.3080695

Wang, R., Chen, F., Chen, Z., Li, T., Harari, G., Tignor, S., Zhou, X., Ben-Zeev, D., & Campbell, A. T. (2014). StudentLife: Assessing mental health, academic performance and behavioral trends of college students using smartphones. Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing, 3–14. https://doi.org/10.1145/2632048.2632054

Xu, X., Liu, X., Zhang, H., Wang, W., Nepal, S., Sefidgar, Y., Seo, W., Kuehn, K. S., Huckins, J. F., Morris, M. E., Nurius, P. S., Riskin, E. A., Patel, S., Althoff, T., Campbell, A., Dey, A. K., & Mankoff, J. (2022). GLOBEM: Cross-dataset generalization of longitudinal human behavior modeling. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 6(4), Article 190, 1–34. https://doi.org/10.1145/3569485

Xu, X., Zou, T., Han, X., Li, Y., Wang, R., Yuan, T., Wang, Y., Shi, Y., Mankoff, J., & Dey, A. K. (2022). TypeOut: Leveraging just-in-time self-affirmation for smartphone overuse reduction. Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3491102.3517476

Bölüm 2: Veri

Proje iki açık veri setine ve uygulamanın kendi topladığı veriye dayanır. LSApp, Model A'yı (kalan oturum süresi); GLOBEM, Model B'yi (uykuya dalma etkisi) eğitir. İki veri setindeki kişiler farklıdır; modeller ortak bir arayüz değişkeni üzerinden birbirine bağlanır (2.4).

LSApp analizi tamamlanmıştır ve Model A'nın kurulabileceğini, ancak hedefinin 5 dakikayı geçmiş oturumlara odaklanması gerektiğini göstermektedir. GLOBEM için veri seti tanımı ve önceden belirlenmiş analiz planı sunulmaktadır.

Verinin yanıtlayacağı sorular. LSApp, AS1'i (devam eden bir oturumun kalan süresi ne doğrulukla tahmin edilebilir?) yanıtlar. GLOBEM, AS2'yi (yatma öncesi kullanım uykuya dalma süresini kişi içi düzeyde ne kadar artırır?) yanıtlar. Uygulamanın kendi verisi ise her iki modelin kişiselleştirilmesini sağlar.

Kapsamlı veri incelemesinin gerekliliği. LSApp incelemesi, ham verinin doğrudan kullanılamayacağını göstermiştir: satırların %59,7'si birebir tekrardır ve ham eşleşmelerin yarısı 0 saniye sürmektedir. Bu nedenle model tasarımından önce tekrar tanımı, oturum tanımı, saat dilimi ve hedef değişken kararları verilmiş ve gerekçeleriyle aşağıda raporlanmıştır.

Analizler Python (pandas, lifelines) ile, yeniden üretilebilir betikler kullanılarak yapılmıştır.

2.1 LSApp: Model A (kalan oturum süresi)

Veri tanımı

Öğe	Bilgi
Tam ad	LSApp (Large dataset of Sequential mobile App usage)
Kaynak makale	Aliannejadi ve ark. (2021), ACM Transactions on Information Systems, 39(3)
Erişim adresi	github.com/aliannejadi/LSApp (dosya: lsapp.tsv.gz)
Lisans	Depoda lisans dosyası yok; README yalnızca atıf istiyor

Öğe	Bilgi
Toplama yöntemi	Android'e özel uSearch uygulaması; katılımcılar Amazon Mechanical Turk üzerinden İngilizce konuşulan ülkelerden alınmış; arka plan sistem paketleri çıkarılıp en popüler 87 uygulama tutulmuş
Kullanıcı sayısı	292
Zaman aralığı	2017-09-09 – 2018-05-17 (yaklaşık 8 ay)
Kişi başına veri	Medyan 5 gün (1–126); medyan 3.220 kayıt (2–156.245)
Boyut ve format	3.658.589 satır, 5 sütun; gzip içinde sekmeyle ayrılmış UTF-8 metin
Zaman damgası	YYYY-MM-DD HH:MM:SS, 1 sn çözünürlük, saat dilimi bilgisi yok

Sütunlar: user_id, session_id, timestamp, app_name, event_type. Hiçbir sütunda eksik değer yoktur.

event_type	Sayı	%
Opened	1.673.261	45,7
Closed	1.667.014	45,6
User Interaction	313.829	8,6
Broken	4.485	0,1

session_id bir telefon oturumudur. 76.247 session'ın %60,7'sinde birden fazla uygulama vardır (ortalama 2,38 uygulama). Bu nedenle uygulama oturumu, session_id ve app_name birlikte kullanılarak yeniden kurulmuştur.

Veri işleme kararları

1. **Tekrarlar.** Satırların %59,7'si (2.185.366) birebir tekrardır. Tüm tekrarları silmek, aynı saniyede kaydedilmiş ayrı olayları da sildiği için bazı oturumları yapay olarak uzatmaktadır: bu yolla oluşan 30 dakikayı aşan 3 oturumun hiçbiri ham veride yoktur. Bu nedenle yalnızca art arda gelen tekrarlar silinmiştir. Bu işlem eşleştirme sonucunu değiştirmez, çünkü eşleştirme kuralı art arda gelen tekrarları zaten tek oturumda toplar.
2. **Eşleştirme.** Her (session_id, app_name) grubunda olaylar sırayla okunur: açık oturum yokken gelen Opened oturum başlatır, açıkken gelen Opened tekrar sayılır, sonraki ilk Closed oturumu kapatır. Başlatılan 1.160.811 oturumun %98,3'ü (1.141.265) bir Closed ile eşleşmiştir. Eşleşmeyen 19.546 oturum atılmaz; sağkalım analizinde sansürlü gözlem olarak kullanılır.
3. **Oturum birleştirme (30 sn).** Ham eşleşmelerin %51,2'si 0 sn sürmektedir; bu, kayıt yazılımının tek bir kullanımı çok sayıda kısa olaya böldüğünü göstermektedir. Aynı kullanıcı aynı uygulamaya 30 saniye içinde dönerse oturum devam sayılır. Bu eşik, 0 saniyelik oturumları %4'e indirirken farklı kullanımları birleştirmeyecek kadar kısadır.
4. **Saat dilimi.** Kullanımın en düşük olduğu saatler veri setinde 09:00–10:00'dır; bu, yerel saatle 04:00–05:00'a denk gelen UTC kaydıyla tutarlıdır. Zaman damgaları UTC kabul edilmiş ve saate

bağlı analizler ABD Doğu saatine (UTC−5) kaydırılarak yapılmıştır. Kaydırmasız sonuçlar duyarlılık analizi olarak parantez içinde verilmiştir.

5. **Model A'nın hedef değişkeni.** Hedef, 5. dakikaya ulaşmış oturumların kalan süresidir. Uyarı yalnızca uzayan oturumlarda anlamlıdır; medyanı 28 saniye olan tipik bir oturumun süresini tahmin etmek ürünün ihtiyacı değildir.

Betimsel bulgular

Birleştirme eşiğinin etkisi.

Birleştirme eşiği	Oturum sayısı	Medyan süre (sn)	Ortalama (sn)	0 sn oturum (%)
Birleştirme yok	1.141.265	0	13,1	51,2
0 sn	324.577	14	46,1	9,3
30 sn (seçilen)	**213.028**	**28**	**73,9**	**4,2**
60 sn	193.085	33	86,0	4,0
120 sn	171.922	41	107,3	3,8

Oturumlar çoğunlukla kısadır; uzun oturumlar nadirdir. Birleştirilmiş oturumların Kaplan–Meier (Kaplan ve Meier, 1958) medyanı 0,5 dakikadır. Oturumların %34'ü 1 dakikayı, %5,3'ü 5 dakikayı, %0,6'sı 15 dakikayı aşmaktadır. 60 dakikayı aşan oturum sayısı 29, 120 dakikayı aşan oturum sayısı 2'dir. Akşam oturumlarının eğrisi tüm oturumlarınkiyle neredeyse aynıdır.

Oturum uzadıkça beklenen kalan süre artar. Bu, Model A'nın temel varsayımını destekler: uzun süredir devam eden bir oturumun daha da uzama eğilimi veride görülmektedir.

Ulaşılan süre	Oturum sayısı	Kalan süre medyanı (dk)	Q1–Q3 (dk)
5 dk	8.114	1,8	0,7–4,1
15 dk	583	4,7	1,8–10,8
30 dk	98	9,7	4,3–35,9

Akşam kullanımı. Oturumların %14,7'si (kaydırmasız: %20,6) 21:00–01:00 arasında başlamaktadır. 292 kullanıcının 273'ünün en az bir akşam oturumu vardır. Hafta içi kullanıcı-gün başına oturum sayısı 398, hafta sonu 358'dir; medyan süreler benzerdir.

Uygulamalar. 87 uygulamanın adları açıktır, kategori bilgisi yoktur. Oturum sayısına göre ilk sıralarda Facebook (191.456), Twitter (84.444), Google Chrome (77.514) ve Reddit (54.995) yer alır. Instagram (43.824), YouTube (11.075) ve Snapchat (2.688) bulunmaktadır; TikTok veri setinde yoktur. 15 dakikayı aşan oturumlarda Facebook (%25,3), Twitter (%14,3) ve Reddit (%11,7) öne çıkar. 30 dakikayı aşan oturumların %38,6'sı ödüllü video ve anket uygulamalarına (Swagbucks) aittir.†

Referans yöntemler (Model A'nın geçmesi gereken çizgi). Her kullanıcının zamana göre ilk %80 verisiyle eğitim, son %20'siyle test yapılmıştır.

Görev	Test n	Kişi × uygulama medyanı MAE (dk)	Genel medyan MAE (dk)	İyileşme
Tüm oturumların süresi	40.572	0,99	1,05	%6
5. dakikadan sonra kalan süre†	1.653	3,06	3,15	%3
15. dakikadan sonra kalan süre†	144	7,15	7,74	%8

Kişinin geçmiş medyanı, herkese aynı tahmini vermekten yalnızca biraz daha iyidir. Model A'nın değeri, bu çizgiyi bağlam bilgisiyle (geçen süre, saat, o günkü kullanım) anlamlı biçimde geçip geçmediğiyle ölçülecektir.

† Bu değerler, tüm birebir tekrarların silindiği veri sürümüyle hesaplanmıştır. İki sürüm arasındaki fark birleştirilmiş oturumlarda %3'ün altındadır (213.028 ve 215.336 oturum; kalan süre medyanları neredeyse aynıdır).

Veri kalitesi sorunları ve çözümleri

Sorun	Bulgu	Çözüm
Birebir tekrarlar	Satırların %59,7'si	Art arda gelen tekrarlar silinir; tüm tekrarları silmek yapay uzun oturumlar ürettiği için uygulanmaz
Parçalanmış oturumlar	Ham eşleşmelerin %51,2'si 0 sn	30 sn birleştirme kuralı
Eşleşmeyen oturumlar	%1,7	Sağkalım analizinde sansürlü gözlem
Saat dilimi bilgisi yok	Kullanım dibi 09:00–10:00	UTC kabulü, UTC−5 kaydırma; kaydırmasız duyarlılık analizi
Uzun oturumların azlığı	30 dk'yı aşan 98 oturum	LSApp kısa ve orta vadeli davranışı öğretir; uzun oturumlar kullanıcının kendi verisinden öğrenilir (2.3)
Kişi başına az veri	Medyan 5 gün	Kişiselleştirme LSApp içinde değil, uygulamanın kendi verisiyle yapılır
Güncellik ve kapsam	2017–2018 verisi; TikTok yok; yalnızca 87 uygulama ve Android	Bulgular güncel kısa video kullanımına dikkatle genellenir; uygulamada tüm uygulamalar izlenir
README'deki 599.635 sayısı	Satır sayısı değil; depodaki data_prep.ipynb not defterinin ürettiği "interaction" sayısı	Analizde satır ve oturum sayıları kendi tanımımızla raporlanır
Aynı saniyedeki olayların sırası	Yalnızca dosya sırasına dayanıyor	Belirsizlik kaynağı olarak dikkate alınır

2.2 GLOBEM: Model B (uykuya dalma etkisi)

GLOBEM, aynı kişilerde hem telefon kullanımını hem Fitbit ile ölçülmüş uykuyu içeren, yazarlarına göre ilk çok yıllı açık pasif algılama veri setidir. Aşağıdaki bilgiler veri setinin tanıtıldığı makaleden (Xu, Zhang ve ark., 2022) alınmıştır.

Veri tanımı

Öğe	Bilgi
Tam ad	GLOBEM Dataset: Multi-Year Datasets for Longitudinal Human Behavior Modeling Generalization
Kaynak makale	Xu, Zhang ve ark. (2022), NeurIPS 2022 Datasets and Benchmarks Track; arXiv:2211.02733
Erişim	physionet.org/content/globem (sürüm 1.0.0), kimlik doğrulamalı erişim
Lisans	PhysioNet Credentialed Health Data License 1.5.0; yalnızca akademik kullanım, yeniden dağıtım ve ticari sistem eğitimi yasak
Örneklem	ABD'de bir üniversitede lisans öğrencileri; 4 veri seti (INS-W_1–4, 2018–2021): 155, 218, 137 ve 195 katılımcı; toplam 705 kişi-yıl, 497 tekil kişi
Süre	Her yıl bahar döneminde 10 hafta; kişi başına yılda ortalama 77,5 ± 8,9 gün
Cihazlar	AWARE tabanlı telefon uygulaması (iOS ve Android); Fitbit Flex2 (2018–2019), Inspire2 (2020–2021)
Format	RAPIDS ile hesaplanmış günlük özellikler (Vega ve ark., 2021); CSV, pid ve date ile indeksli

Makalede raporlanan ilgili bulgular. Gece ekran kilidi açma sayısı ve son iki haftanın uyku süresi, ruh sağlığı etiketiyle tüm yıllarda en tutarlı ilişkiyi gösteren özelliklerdir ($|\rho| > 0{,}1$). Katılımcılar hafta sonları uyku açığını kapatmaya çalışmaktadır. COVID sonrası veri setlerinde telefon kullanımı artmış, hareketlilik azalmıştır. Bu bulgular, gece kullanımı ile uyku arasında aranan sinyalin veri setinde var olduğunu göstermektedir.

Kullanılacak değişkenler

Rol	Değişken (ana uyku, ham sürüm)	Not	Eksik veri*
Girdi	Akşam (18–24) ekran: sumduration, countepisode	Yatma öncesi kullanımın yaklaşığı	%14,4
Girdi	firstbedtime, lastbedtime	Kullanımı yatma saatine göre ayırmak için	%36,3
Hedef (aday 1)	sumdurationtofallasleep	Uykuya dalma süresi	%35,6
Hedef (aday 2)	Yatakta kaybedilen süre = sumdurationinbed − sumdurationasleep	Uykuya dalma + gece uyanıklığı + uyandıktan sonra yatakta kalma	%34,5–35,6
Yedek hedef	avgefficiency	Uyku verimliliği	%36,3
Bağlam	Hafta içi / sonu, veri seti (COVID öncesi / sonrası), platform	–	–

** Makalede dört veri setinin toplamı için raporlanan oranlardır.*

Önceden belirlenmiş analiz planı

Analiz tercihleri sonuçlar görülmeden önce aşağıdaki gibi sabitlenmiştir:

1. **Tarih eşleştirmesi.** Bir tarihteki uyku özelliğinin o tarihte başlayan geceye mi biten geceye mi ait olduğu RAPIDS belgesinden ve veriden doğrulanır: uyku(D), D ve D+1 gecelerinin 00–06 ekran kullanımıyla karşılaştırılır; uyku sırasında kullanım düşük olacağından daha negatif ilişkili gece doğru hizalamadır.
2. **Hedef değişken kuralı.** sumdurationtofallasleep gecelerin yarısından fazlasında 0 ise bu değişken gürültülü kabul edilir ve hedef olarak yatakta kaybedilen süre kullanılır.
3. **Betimsel istatistikler.** Her veri seti için kişi ve kişi-gün sayıları, kişi başına hem ekran hem uyku verisi olan gece sayısı, hedef ve girdi değişkenlerinin dağılımları ve yatma saati dağılımı (hafta içi / sonu).
4. **İlişki analizi.** Akşam ekran süresi ile hedef arasındaki Spearman korelasyonu üç düzeyde: ham, kişi içi (kişinin kendi ortalamasına göre merkezlenmiş) ve kişiler arası.
5. **Karma etkili model.** Hedef = kişi içi akşam ekran süresi (10 dakikalık birim) + kişiler arası akşam ekran süresi + hafta sonu + veri seti + kişiye özgü rastgele kesişim (yakınsarsa rastgele eğim). Referans yöntem: kişinin ortalama uykuya dalma süresi.
6. **Duyarlılık analizleri.** Ters nedensellik kontrolü için aynı model gece (00–06) ekran kullanımıyla; yalnızca Android kullanıcılarıyla; COVID öncesi (DS1–2) ve sonrası (DS3–4) ayrı ayrı.
7. **Gizlilik.** Analiz yerel bilgisayarda yapılır; yalnızca toplu istatistik raporlanır; saçılım grafikleri yerine en az 5 gözlemli hücreleri gösteren yoğunluk grafikleri kullanılır.

Ters nedensellik önlemi. Gece (00–06) kullanımı uyanıklığın sonucu olabileceği için ana analiz yatma saatinden önceki kullanıma dayanır.

Bulguların kapsamı. GLOBEM'e kimlik doğrulamalı erişim süreci bu raporun hazırlandığı aşamada tamamlanmadığından, bu bölümde yalnızca veri setinin makalede raporlanan özellikleri kullanılmıştır. Model B'nin etki büyüklüğü yukarıdaki önceden belirlenmiş planla üretilecektir; bu nedenle raporda bu etki için sayısal bir değer öne sürülmemektedir.

2.3 Uygulamanın Kendi Verisi

Aynı kişide hem oturum hem uyku verisini içeren tek kaynak uygulamanın kendisidir; bu nedenle kişiselleştirme ve uzun oturumların öğrenilmesi bu veriye dayanır.

Veri	Kaynak	Ne zaman	Kullanım
Uygulama oturumları	UsageStatsManager	Tüm gün, pasif	Model A'nın kişiselleştirilmesi; LSApp'te az bulunan uzun oturumların öğrenilmesi
Uyku oturumları	Health Connect (giyilebilir cihaz)	Her sabah	Model B'nin kişiselleştirilmesi

Veri	Kaynak	Ne zaman	Kullanım
Sabah öz-değerlendirmesi	Uygulama	Her sabah	Uykuya dalma süresinin birincil ölçümü; giyilebilir cihazı olmayan kullanıcılar ve doğrulama

LSApp'te kişi başına medyan 5 gün veri bulunduğundan, LSApp içinde kişiselleştirmenin katkısı sınırlı kalmıştır (%3–8). Uygulama ise her kullanıcıdan haftalarca kesintisiz veri toplar; kişiselleştirme bu nedenle uygulama verisine dayanır.

Pilot çalışma. Capstone kapsamında ekip üyelerinden 2 hafta boyunca KVKK onamıyla küçük bir pilot veri seti toplanacaktır. Pilot, aynı kişilerde oturum ve uyku verisini bir arada sunarak 2.4'teki varsayımın sınırlı ölçüde test edilmesini sağlar. Uygulamanın aktif akşam penceresi, Sistem Mimarisi bölümünde belirtildiği gibi ilk prototipte hedef yatma saatinden 60 dakika önce başlar.

2.4 İki Veri Setinin Bağlanması

LSApp ve GLOBEM aynı kişileri içermez ve birleştirilmeleri gerekmez: iki model ortak bir arayüz değişkeni üzerinden bağlanır. Bu değişken, **yatma saatinden önceki kullanım dakikasının kişinin kendi normaline göre ifadesidir.**

1. Model A (LSApp) devam eden oturumun kalan süresini tahmin eder; buradan o akşamın toplam yatma öncesi kullanımı hesaplanır.
2. Bu kullanım, kişinin normal akşam kullanımına göre göreli bir değere çevrilir.
3. Model B (GLOBEM) bu göreli kullanıma karşılık gelen ek uykuya dalma süresini verir.
4. 2–3 hafta sonra her iki model kullanıcının kendi verisiyle güncellenir.

Arayüz değişkeninin LSApp tarafı. Kişi-gün başına akşam 18:00–24:00 kullanım süresi hesaplanmıştır (UTC−5 kaydırmalı):

Kaynak	Kişi-gün	Medyan (dk)	Q1–Q3 (dk)	Ortalama (dk)
LSApp, tüm günler	2.973	9,7	0,0–35,4	24,0
LSApp, akşam kullanımı olan günler	2.123	22,1	7,3–48,3	33,6

Kaydırmasız hesapta medyanlar 14,0 ve 25,2 dakikadır. GLOBEM tarafındaki akşam ekran süresi dağılımı, 2.2'deki analiz planının betimsel istatistikler adımında hesaplanacaktır.

Ölçek farkı neden sorun değildir? LSApp yalnızca izlenen 87 uygulamanın açık kalma süresini, GLOBEM ise ekran kilidinin açık olduğu tüm süreyi ölçer; bu nedenle LSApp değerlerinin daha düşük çıkması beklenir. Arayüz değişkeni mutlak dakika yerine kişinin kendi normaline göre tanımlandığı için bu ölçek farkı modeller arasında taşınmaz. Bu yaklaşım, GLOBEM'in de her özelliği kişinin kendi medyanına ve 5–95 yüzdelik aralığına göre normalleştirilmiş biçimde sunmasıyla uyumludur (Xu, Zhang ve ark., 2022).

Varsayım. Uykuya etki kullanımın miktarına ve zamanlamasına bağlıdır, hangi uygulamada geçtiğine bağlı değildir. Uygulama türüne özgü etkiler ancak aynı kişide iki veriyi birlikte içeren uygulama verisiyle öğrenilebilir.

2.5 Etik, Lisans ve Veri Gizliliği

Veri	Lisans ve koşullar	Uygulanan önlemler
LSApp	Depoda lisans yok; README atıf istiyor	Yalnızca akademik kullanım ve atıf; veri yeniden dağıtılmaz; ticari kullanım gerekirse yazarlardan izin alınır
GLOBEM	PhysioNet Credentialed Health Data License 1.5.0	Analiz yalnızca yerel bilgisayarda; ham veri bulut klasörlerine, kod depolarına veya yapay zekâ araçları dahil üçüncü taraf hizmetlere yüklenmez; yalnızca toplu istatistik raporlanır; yeniden tanımlama girişimi yapılmaz; proje sonunda silinir
Uygulama verisi	KVKK (6698 sayılı Kanun); uyku ve gece kullanımı sağlık verisi olarak değerlendirilir	Aydınlatma metni; ayrı ve geri alınabilir açık rıza; yalnızca süre, zaman ve uygulama kategorisi toplanır; içerik toplanmaz; tamamen cihazda işleme; tek dokunuşla silme; 18 yaş sınırı
Pilot veri	KVKK	Ekip üyelerinden yazılı onam; çekilme hakkı; pilot sonunda silme

LSApp katılımcıları farklı İngilizce konuşulan ülkelerden gelebilir ve veri 2017–2018'de toplanmıştır. GLOBEM ise tek bir ABD üniversitesinin öğrencilerinden oluşur. Her iki veri seti de Türkiye'deki genç yetişkinleri temsil etmez; bu nedenle açık veri setleri yalnızca başlangıç modeli için kullanılır ve asıl uyarlama kullanıcının kendi verisiyle yapılır.

2.6 Sonuç

Veri incelemesi Model A'nın kurulabileceğini ve hangi koşullarda değer üreteceğini netleştirmiştir.

- **Ham veri doğrudan kullanılamaz.** Tekrar, eşleştirme ve birleştirme kuralları uygulandıktan sonra LSApp'ten 213.028 anlamlı uygulama oturumu elde edilmiştir.
- **Oturum uzadıkça kalan süre artar.** 5. dakikada kalan süre medyanı 1,8 dakika, 15. dakikada 4,7 dakika, 30. dakikada 9,7 dakikadır.
- **Model A'nın geçmesi gereken çizgi bellidir.** 5. dakikadan sonra kalan süre için kişisel medyanla MAE 3,06 dakika, 15. dakikadan sonra 7,15 dakikadır.
- **Uzun oturumlar ve kişiselleştirme uygulama verisine dayanır.** LSApp'te 30 dakikayı aşan oturum azdır ve kişi başına veri kısadır; bu nedenle açık veri seti başlangıç modelini, uygulamanın kendi verisi kişiselleştirmeyi sağlar.
- **Model B için sinyalin varlığı literatürde gösterilmiştir.** GLOBEM'de gece telefon kullanımı ve uyku, tüm yıllarda tutarlı ilişki gösteren özellikler arasındadır; etkinin büyüklüğü önceden belirlenmiş planla ölçülecektir.

2.7 Kaynakça

Aliannejadi, M. (t.y.). LSApp: Large dataset of sequential mobile app usage [Veri seti]. GitHub. https://github.com/aliannejadi/LSApp

Aliannejadi, M., Zamani, H., Crestani, F., & Croft, W. B. (2021). Context-aware target apps selection and recommendation for enhancing personal mobile assistants. ACM Transactions on Information Systems, 39(3), Article 29. https://doi.org/10.1145/3447678

Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C.-K., & Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. Circulation, 101(23), e215–e220. https://doi.org/10.1161/01.CIR.101.23.e215

Kaplan, E. L., & Meier, P. (1958). Nonparametric estimation from incomplete observations. Journal of the American Statistical Association, 53(282), 457–481.

Kişisel Verilerin Korunması Kanunu, 6698 sayılı Kanun. (2016, 7 Nisan). Resmî Gazete (Sayı: 29677).

Vega, J., Li, M., Aguillera, K., Goel, N., Joshi, E., Khandekar, K., Durica, K. C., Kunta, A. R., & Low, C. A. (2021). Reproducible analysis pipeline for data streams: Open-source software to process data collected with mobile devices. Frontiers in Digital Health, 3.

Xu, X., Zhang, H., Sefidgar, Y., Ren, Y., Liu, X., Seo, W., Brown, J., Kuehn, K., Merrill, M., Nurius, P., Patel, S., Althoff, T., Morris, M. E., Riskin, E., Mankoff, J., & Dey, A. K. (2022). GLOBEM dataset: Multi-year datasets for longitudinal human behavior modeling generalization. Advances in Neural Information Processing Systems 35: Datasets and Benchmarks Track. https://arxiv.org/abs/2211.02733

Xu, X., Zhang, H., Sefidgar, Y., Ren, Y., Liu, X., Seo, W., Brown, J., Kuehn, K., Merrill, M., Nurius, P., Patel, S., Althoff, T., Morris, M. E., Riskin, E., Mankoff, J., & Dey, A. K. (2022). GLOBEM Dataset (Sürüm 1.0.0) [Veri seti]. PhysioNet. https://physionet.org/content/globem

Bölüm 3: Teknoloji İncelemesi

3.1 Giriş

Screen2Sleep AI'ın teknoloji seçimi, uygulama kullanımını ölçme, devam eden oturumun kalan süresini tahmin etme ve bu tahmini uyku değerlendirmesine aktarma gereksinimleri etrafında yapılmaktadır. Kullanışlı bir sistem için yalnızca tahmin doğruluğu yeterli değildir. Veri erişimi, Android'in arka plan çalışma sınırları, pil tüketimi, mahremiyet ve kullanıcıya sunulan açıklamanın anlaşılabilirliği birlikte değerlendirilmelidir.

Bu inceleme kapsamında kullanım algılama için Android UsageStatsManager, ertelenebilir işler için WorkManager ve Model A için sağkalım analizi ile makine öğrenmesi yöntemleri ele alınmaktadır. Amaç, küçük bir pilotta uygulanabilecek ve daha sonra geliştirilebilecek bir teknoloji yapısı belirlemektir. Karşılaştırmadaki performans ve kaynak tüketimi değerlendirmeleri başlangıç beklentileridir; proje üzerinde ölçülmüş sonuçlar değildir.

3.2 Teknolojilere Genel Bakış ve Projeyle İlişki

Kullanım algılama ve çalışma modları

UsageStatsManager, Android'de uygulama kullanım istatistiklerine ve belirli zaman aralıklarındaki kullanım olaylarına erişim sağlar. Başka uygulamalara ait verileri okumak için kullanım erişimi gerekir. Manifest dosyasındaki izin bildirimi tek başına yeterli değildir; kullanıcı sistem ayarlarından erişimi açmalıdır.

Model A'nın oturumları oluşturabilmesi için yalnızca günlük toplam süreler yeterli değildir. queryEvents() üzerinden alınan zaman damgalı olaylar kullanılmalıdır. Android, ayrıntılı olayları sınırlı süre sakladığından gerekli kayıtların düzenli olarak yerel depoya aktarılması planlanmaktadır. İzin iptali veya veri okunamaması, "telefon kullanılmadı" şeklinde yorumlanmamalıdır.

ACTIVITY_RESUMED ve ACTIVITY_PAUSED olayları, uygulama etkinliklerinin yaşam döngüsünü izlemeye yardımcı olur. Ekranın etkileşimli olup olmadığını gösteren olaylar da oturum oluşturmayı destekleyebilir. Ancak aynı uygulamanın farklı ekranları ayrı etkinlik olayları üretebildiği için her olay çifti bağımsız uygulama oturumu sayılmamalıdır.

Projede oturum tanımı, "belirli bir uygulamanın kullanıcı tarafından ön planda kullanıldığı dönem" olarak önerilmektedir. Uygulama içi geçişler, başka uygulamaya kısa süreli geçişler ve ekran kapanmaları için açık kurallar belirlenecektir. Kısa bir geçişin aynı oturuma dahil edilip edilmeyeceği pilot veride değerlendirilecektir. Ön planda bulunma, kullanıcının sürekli dikkat verdiğinin kesin kanıtı olarak kabul edilmeyecektir.

Tüm gün pasif çalışma

Pasif modda amaç, sistemi sürekli çalıştırmak yerine Android'in kaydettiği geçmiş olayları belirli aralıklarla okuyarak kişisel kullanım geçmişi oluşturmaktır. WorkManager, bu tür ertelenebilir görevlerin planlanması için uygundur ve işlerin uygulama veya cihaz yeniden başlatmalarından sonra sürdürülmesini destekler.

Önerilen işleyişte son başarılı okuma zamanı saklanacak, yeni kayıtlar yerel depoya aktarılacak ve yinelenen kayıtlar ayıklanacaktır. Gündüz verileri Model A'nın kişisel geçmiş özelliklerini oluşturmak için kullanılacak; bu modda davranışsal müdahale bildirimi üretilmeyecektir.

WorkManager'ın periyodik görevleri için minimum tekrar aralığı 15 dakikadır ve görevlerin tam belirtilen anda çalışması garanti edilmez. Bu nedenle WorkManager, saniyelik canlı oturum takibinin yerine kullanılmamalıdır.

Akşam penceresinde aktif çalışma

Aktif mod, hedef yatma saatinden önce tanımlanan sınırlı bir zaman penceresinde daha sık kullanım kontrolü ve model çıkarımı yapılmasını amaçlamaktadır. Pencerenin uzunluğu ve sorgulama sıklığı pilotta belirlenecektir.

Android 12 ve üzerini hedefleyen uygulamalarda, arka plandan foreground service başlatmak belirli istisnalar dışında kısıtlanmıştır. Bu nedenle akşam modunun herhangi bir kullanıcı etkileşimi olmadan her

cihazda tam saatinde başlayacağı varsayılmamalıdır. İlk prototipte kullanıcı tarafından başlatılan bir akşam izleme modu değerlendirilmelidir.

Foreground service kullanılacaksa hedef Android sürümüne uygun servis türü ve izin gereksinimleri karşılanmalıdır. Servis kullanımı, tek başına sınırsız arka plan çalışma garantisi sağlamaz. Seçilen yaklaşım farklı cihazlarda doğrulanmalıdır.

Projenin mevcut bildirim kuralı korunarak hedef yatma saatinden sonra müdahale bildirimleri durdurulacaktır. Bununla birlikte ertesi gün okunabilen kullanım kayıtları, gerçekleşen oturumları değerlendirmek için kullanılabilecektir. Kullanıcının "önemli" olarak işaretlediği oturumlarda da müdahale susturulacaktır.

Pil tüketimi ve veri minimizasyonu

Pil tüketimini sınırlamak için aşağıdaki tasarım tercihleri önerilmektedir:

- Gündüz kayıtlarının toplu okunması.
- Sık kontrollerin yalnızca akşam penceresinde yapılması.
- Modelin her kontrolde gereksiz yere yeniden çalıştırılmaması.
- Model A için gerekli olmayan konum, mikrofon veya içerik verilerinin toplanmaması.
- Ağır eğitim ve güncelleme işlemlerinin uygun zamanda yürütülmesi.
- Kullanım verilerinin mümkün olduğunca cihazda işlenmesi.

Bu tercihler düşük tüketimi hedeflemektedir; "düşük pil tüketimi" henüz doğrulanmış bir sonuç değildir. Pilot değerlendirmede pasif ve aktif modların ek enerji tüketimi, olay yakalama gecikmesi, eksik kayıt oranı ve model çıkarım süresi ölçülmelidir.

Model A: Kalan oturum süresi tahmini

Tahmin hedefi ve girdiler

Toplam oturum süresi (T), o ana kadar geçen süre (t) olduğunda kalan süre (R=T-t) olarak tanımlanır. Model, oturumun hâlâ devam ettiğini dikkate almalıdır.

Önerilen girdiler; geçen süre, uygulama veya kategorisi, günün saati, hafta içi/hafta sonu bilgisi, tahmin anına kadarki günlük kullanım ve kişinin geçmiş oturum istatistikleridir. Geçmiş istatistikler yalnızca tahmin anından önceki verilerle hesaplanmalıdır.

Model A'nın çıktısı, **mevcut oturumun kalan süresidir**. Bu çıktı tek başına gecenin kalan bütün telefon kullanımını göstermez. Kullanıcı başka bir uygulamaya geçerse yeni bir oturum oluşabilir; Model B'ye aktarılacak toplam kullanım hesabında bu ayrım korunmalıdır.

Referans yöntem

İlk referans yöntem şu şekilde tanımlanacaktır:

Tahmini kalan süre = maksimum(0, kişinin geçmiş medyan oturum süresi − geçen süre).

Bu yöntem basit ve anlaşılırdır; ancak oturum kişisel medyanı aştığında sürekli sıfır tahmini üretebilir. Bu nedenle ikinci bir karşılaştırma olarak, geçmişte mevcut geçen süreden daha uzun sürmüş oturumların

kalan süre medyanı da değerlendirilecektir. Yeterli kişisel veri yoksa uygulama veya kategori düzeyinde başlangıç istatistikleri kullanılacaktır.

Sağkalım analizi

Sağkalım analizinde olay, oturumun sona ermesidir. Oturumun devam etme olasılığı modellenerek belirli bir süre daha sürme ihtimali hesaplanabilir. Cox ve hızlandırılmış başarısızlık zamanı modelleri (AFT), başlangıç adaylarıdır. Cox modelinde orantılı risk varsayımı, parametrik AFT modellerinde ise seçilen dağılımın uygunluğu değerlendirilmelidir.

Sabit bağlamlı bir süre modelinde, S(t | x) oturumun t anından uzun sürme olasılığı olmak üzere:

$$P(R > r \mid T > t, x) = S(t + r \mid x) / S(t \mid x)$$

Bu koşullama, oturumun zaten belirli bir süre devam etmiş olduğu bilgisini tahmine dahil eder. Çıktıdan medyan kalan süre ve uygun yüzdeliklere dayalı tahmin aralığı elde edilmesi hedeflenmektedir.

Gözlem sona erdiğinde hâlâ devam ettiği bilinen oturumlar sağdan sansürlü olarak temsil edilebilir. Ancak eksik kapanış kaydı veya Broken etiketi otomatik olarak geçerli sansürlü gözlem sayılmamalıdır. Önce oturumun hangi ana kadar gerçekten devam ettiğinin bilindiği ve veri kaybının nedeni incelenmelidir.

Gradyan artırmalı ağaçlar

Gradyan artırmalı ağaçlar, saat, uygulama ve geçmiş davranış arasındaki doğrusal olmayan ilişkileri modellemek için değerlendirilecektir. XGBoost'un AFT amaç fonksiyonu, sansürlü süre etiketlerini desteklediğinden aday yöntemlerden biridir. Standart regresyon ile sağkalım amaç fonksiyonu aynı kabul edilmemelidir; bitişi bilinmeyen oturumların son gözlenen süresini gerçek bitiş süresi gibi kullanmak hatalı etiket üretir.

Zaman serisi ve sıralı modeller

LSTM veya GRU gibi sıralı modeller, önceki uygulama geçişleri ve oturum dizilerini değerlendirmek üzere ileri aşama adaylarıdır. İlk prototipte bunların tercih edilmesi zorunlu değildir. Daha karmaşık modeller ancak yeterli veri bulunduğunda ve daha basit yöntemlere göre ölçülebilir katkı sağladığında kullanılmalıdır. Sansürlü gözlemleri işlemek için sıradan bir süre regresyonundan farklı eğitim hedefleri gerekebilir.

Değerlendirme planı

Model A için şu değerlendirme düzeni önerilmektedir:

- Eğitim ve test verisi zaman sırasına göre ayrılacaktır.
- Aynı oturumdan üretilen farklı tahmin anları aynı veri bölümünde tutulacaktır.
- Yeni kullanıcı performansı, kullanıcı bazlı ayrı bir testle değerlendirilecektir.
- Tamamlanmış test oturumlarında dakika cinsinden ortalama ve medyan mutlak hata raporlanacaktır.
- Sansürlü gözlemler için uygun sağkalım ölçütleri kullanılacaktır.

- Tahmin aralıklarının kapsama oranı ve genişliği birlikte incelenecektir.
- Gece oturumları ve uzun oturumlar ayrıca değerlendirilecektir.

Başarılı model seçimi yalnızca genel doğruluğa dayanmayacaktır. Kişisel referans yönteme göre katkı, tahmin belirsizliği, cihazdaki çalışma maliyeti ve veri eksikliğine dayanıklılık birlikte dikkate alınacaktır.

Uyku ölçümü

Screen2Sleep AI'ın birincil çıktısı olan uykuya dalma süresi üç kaynaktan elde edilebilir: Android'in Health Connect platformu üzerinden giyilebilir cihaz verisi, kullanıcının sabah öz-değerlendirmesi ve dolaylı bir gösterge olarak telefonun son etkileşim zamanı. Bu bölümde her kaynağın teknik olanakları ve sınırlılıkları ele alınmakta, ardından projede kullanılacak hibrit yaklaşım gerekçelendirilmektedir.

Health Connect. Health Connect, Android cihazlarda sağlık ve fitness verilerini farklı uygulamalar arasında ortak bir yapıda saklayan platformdur. Uyku verisi SleepSessionRecord veri tipinde, başlangıç ve bitiş zamanı ile uyku evrelerini içeren bir aralık kaydı olarak tutulmaktadır. Bu veriyi okumak için android.permission.health.READ_SLEEP izni gerekmektedir. Proje açısından iki teknik kısıt kritiktir: uygulama arka planda çalışırken veri okuyabilmek için READ_HEALTH_DATA_IN_BACKGROUND, 30 günden eski veriye erişebilmek için READ_HEALTH_DATA_HISTORY izninin ayrıca beyan edilmesi gerekir. Ayrıca uygulamanın Google Play'de yayımlanabilmesi için eriştiği veri tiplerini ve veri kullanım amacını beyan etmesi zorunludur (Android Developers, t.y.). Bu kısıtlar, uygulamanın gün boyu pasif çalışma tasarımını ve etik bölümünde ele alınan veri şeffaflığı ilkelerini doğrudan etkilemektedir.

Giyilebilir cihazların doğruluğu. Health Connect yalnızca bir veri aktarım katmanıdır; verinin doğruluğu kaynağı olan cihaza bağlıdır. Polisomnografiyle yapılan karşılaştırmalar, tüketici cihazlarının uykuyu yüksek duyarlılıkla tespit ettiğini, ancak uyanıklığı tespit etmede zayıf kaldığını göstermektedir (Chinoy ve ark., 2021; Schyvens ve ark., 2025). Uykuya dalma süresi, yatağa girdikten sonraki uyanıklık süresinin doğru ölçülmesine dayandığından, giyilebilir veri bu çıktı için tek başına güvenilir değildir. Bunun yanında her kullanıcının giyilebilir cihazı yoktur; bu nedenle sistem cihaz olmadan da çalışabilmelidir.

Sabah öz-değerlendirmesi. Uyku günlüğü, öznel uyku ölçümünde altın standart kabul edilmektedir (Carney ve ark., 2012). Screen2Sleep AI'da kullanıcıya her sabah, Consensus Sleep Diary'nin temel maddelerinden uyarlanan kısa bir anket sunulacaktır: yatağa girme saati, uyumaya çalışma saati, uykuya dalma süresi, gece uyanma sayısı, son uyanma saati ve uyku kalitesi (beşli ölçek). Anketin kısa tutulması, uzun süreli kullanımda katılım yükünü azaltmayı amaçlamaktadır.

Telefonun son etkileşim zamanı. UsageStatsManager ile elde edilen son ekran etkileşimi, kullanıcının telefonu bıraktığı anı göstererek uyku başlangıcı için dolaylı bir gösterge sağlayabilir. Ancak telefonu bırakmak uykuya dalmak anlamına gelmediğinden, bu veri tek başına ölçüm olarak değil, öz-değerlendirme ve cihaz verisiyle karşılaştırma amacıyla kullanılacaktır.

Yöntem	Ne ölçer	Uykuya dalma süresi için uygunluk	Kullanıcı yükü / maliyet	Projedeki rolü
Polisomnografi (PSG)	Beyin dalgaları, uyku evreleri	Yüksek (referans yöntem)	Çok yüksek; laboratuvar gerekir	Kullanılmayacak; yalnızca literatürde referans
Giyilebilir cihaz (Health Connect)	Hareket ve nabız	Sınırlı; uyanıklığı zayıf tespit eder	Düşük; cihaz gerekir	Destekleyici, isteğe bağlı nesnel veri
Sabah öz-değerlendirmesi	Kullanıcının algıladığı uyku	Öznel ama standart	Çok düşük	Birincil ölçüm
Telefon son etkileşimi (UsageStatsManager)	Telefonun bırakıldığı an	Dolaylı gösterge	Yok; pasif	Karşılaştırma ve yatma saati göstergesi

Uyku Ölçüm Seçenekleri

Bu karşılaştırma doğrultusunda Screen2Sleep AI'da **hibrit bir ölçüm yaklaşımı** benimsenmiştir: sabah öz-değerlendirmesi her kullanıcı için birincil ölçüm olarak kullanılacak, Health Connect verisi mevcutsa destekleyici olarak eklenecek, telefonun son etkileşim zamanı ise iki kaynağı karşılaştırmak için kullanılacaktır.

Değerlendirmede tek bir yöntemin bütün ölçütlerde üstün olmadığı görülmektedir. PSG en doğru yöntem olmakla birlikte ev ortamında ve uzun süreli kullanım için uygun değildir. Giyilebilir cihazlar düşük yükle nesnel veri sağlar, ancak uyanıklığı zayıf tespit ettikleri için (Chinoy ve ark., 2021; Schyvens ve ark., 2025) uykuya dalma süresi için tek başına yeterli değildir ve her kullanıcıda bulunmazlar. Sabah öz-değerlendirmesi, standart bir uyku günlüğüne dayandığında (Carney ve ark., 2012) tüm kullanıcılar için düşük maliyetle uygulanabilir. Bu nedenle sabah öz-değerlendirmesi birincil ölçüm olarak seçilmiş; giyilebilir veri ve telefon son etkileşimi ise destekleyici kaynaklar olarak konumlandırılmıştır.

Model B: Uykuya dalma etkisi ve kişiselleştirme

Model B'nin temel görevi, Model A tarafından sağlanan "akşam penceresindeki tahmini kullanım süresi" bilgisini alarak, bu kullanımın kullanıcının kendi baz çizgisine (kişisel ortalamasına) kıyasla uykuya dalma süresinde (sleep onset latency) meydana getireceği ek gecikmeyi tahmin etmektir.

1. **Karma Etkili Modeller (Mixed-Effects Models):** Popülasyon genelindeki sabit etkiler (gece ekran süresi arttıkça uykuya dalmanın gecikmesi yönündeki genel biyolojik eğilim) ile bireye özgü rastgele kesişim ve eğimleri (random effects) ayrıştırır. GLOBEM açık veri setindeki çoklu kullanıcı varyansını modellemek için temel istatistiksel çatı olarak kullanılır.
2. **Bayesçi Güncelleme (Bayesian Updating):** "Soğuk başlangıç" (cold-start) problemini aşmak için GLOBEM üzerinde öğrenilen parametreler öncül dağılım (prior) olarak kabul edilir. Kullanıcı uygulamayı kullanmaya başladıkça ve sabahları Health Connect üzerinden yeni uyku verileri geldikçe (likelihood), bireyin parametreleri sonsal dağılıma (posterior) evrilir. Bu sayede 2–3 hafta içinde sistem tamamen kişiselleşir.

3. **Cihazda Öğrenme ve LiteRT (On-Device ML):** Android ekosisteminde kullanıcı gizliliğini (KVKK) korumak ve sunucu maliyetini sıfıra indirmek adına model çıkarımı ve Bayesçi güncellemeler Google LiteRT (TensorFlow Lite Runtime) aracılığıyla doğrudan cihaz üstünde çalıştırılır. Ham sensör ve uyku logları hiçbir zaman harici bir sunucuya iletilmez.

Müdahale ve bildirim katmanı

Screen2Sleep AI'ın müdahale ve bildirim katmanı JITAI bileşenleriyle aşağıdaki şekilde tanımlanır:

Uzak sonuç: Yatma öncesi istemsiz kullanımı azaltmaya ve daha düzenli uyku rutinine katkıda bulunmak. Bu, klinik tedavi iddiası değildir.

Yakın sonuç: Müdahale sonrasındaki kısa pencerede oturumun sonlandırılması, hedef yatma saatinin aşılmaması veya kullanıcının bilinçli olarak devam etmeyi seçmesi.

Karar anı: Yalnızca kullanıcının seçtiği akşam penceresinde, aktif bir hedef-uygulama oturumu varken ve yeterli veri bulunduğunda.

Uyarlama değişkenleri: Model A kalan süre dağılımı, hedef yatma saatine kalan zaman, kişinin geçmiş kullanım normali, Model B tahmini ve belirsizliği, son uyarı zamanı, günlük uyarı sayısı ve sessize alma tercihi.

Müdahale seçenekleri: Hiçbir şey yapmama; tek satırlık bilgilendirme; kısa ara önerisi; "bu oturum önemli"; "bugün sessize al"; özelliği kapatma.

Karar kuralı: İzin açık, uyarı sıklığı sınırı aşılmamış, tahmin güvenilir ve beklenen yarar müdahale yükünden yüksekse hafif uyarı göster; aksi halde sessiz kal. Bu kural pilotta test edilecek bir tasarım önerisidir.

Önerilen uyarı dili: "Bu oturumun yaklaşık 15–30 dakika daha sürmesi mümkün. Hedef yatma saatini aşabilirsin. Şimdi ara vermek ister misin?" Model B kalibrasyonu doğrulanmadan "10 dakika daha geç uyuyacaksın" gibi kesin nedensel cümle kullanılmayacaktır.

Kaçınılacak dil: "Bağımlısın", "telefonu hemen bırakmalısın", "derin uykun %30 azalacak" gibi klinik, tehditkâr veya veriyle doğrulanmamış kesin ifadeler.

Bildirim ilkeleri: Hedef yatma saatinden sonra müdahale bildirimi gönderilmez; aynı risk için tekrarlayan bildirimler bastırılır; kullanıcı tek dokunuşla oturumu/akşamı sessize alabilir; sessize alma "başarısızlık" olarak puanlanmaz.

Değerlendirme ölçütleri: Uyarı gösterilme ve görülme oranı, 5/10/15 dakika içinde oturum sonlandırma, tekrar açma, yanlış uyarı, günlük bildirim sayısı, bildirim yorgunluğu, kullanıcı memnuniyeti, ertesi sabah uykuya dalma süresi, tahmin aralığı kapsaması ve ek pil tüketimi.

3.3 Karşılaştırma ve Değerlendirme

Aşağıdaki tablo proje için ön değerlendirmedir; ölçülmüş performans sıralaması değildir.

Model A Yöntemleri Karşılaştırma Tablosu

Yöntem	Güçlü yön	Sınırlılık	Maliyet ve uygulama kolaylığı	Projedeki rol
Kişisel medyan referansı	Çok anlaşılır, hızlı ve kolay uygulanır	Bağlamı sınırlı kullanır; geçen süre medyanı aşınca zayıflar	Çok düşük hesaplama yükü	Zorunlu başlangıç karşılaştırması
Cox sağkalım modeli	Sansürlü veriyi kullanır; katsayılar yorumlanabilir	Orantılı risk varsayımı değerlendirilmelidir	Görece düşük çıkarım yükü	Açıklanabilir aday
Parametrik AFT	Süre ve tahmin dağılımı üretimine uygundur	Dağılım seçimine duyarlıdır	Küçük modellerde düşük çıkarım yükü	İlk prototip için öncelikli aday
XGBoost-AFT	Doğrusal olmayan ilişkileri ve sansürlü etiketleri ele alabilir	Model boyutu ve mobil uygulama entegrasyonu değerlendirilmelidir	Eğitim ve entegrasyon yükü daha yüksek olabilir	AFT'ye karşı performans adayı
LSTM / GRU	Kullanım sırasını değerlendirebilir	Veri, açıklanabilirlik ve eğitim karmaşıklığı açısından daha talepkârdır	Görece yüksek geliştirme yükü	İleri aşama araştırma seçeneği

Mahremiyet, tek başına algoritmanın adıyla belirlenmez. Her yöntemde verinin nerede saklandığı ve işlendiği önemlidir. Erişilebilirlik açısından kullanıcıya model terimleri yerine anlaşılır süre aralıkları sunulmalıdır. Ölçeklenebilirlik değerlendirmesinde ise eğitim süresi, cihazdaki model boyutu ve çıkarım gecikmesi ölçülmelidir.

Model B Yöntemleri Karşılaştırma Tablosu

Ölçüt	Karma Etkili Modeller (Mixed-Effects Models)	Bayesçi Güncelleme (Bayesian Updating)	Cihazda Öğrenme (LiteRT / On-Device ML)
Çalışma Mantığı	Sabit popülasyon etkileri ile kişiye özgü rastgele kesişim/eğimleri (random effects) ayırır.	Popülasyon öncülünü (prior), yeni gecelerin verisi geldikçe (likelihood) sonsal dağılıma (posterior) evirir.	Önceden eğitilmiş kompakt modeli mobil işlemcide (CPU/NNAPI) koşturur; son katmanları yerel veriyle günceller.
Soğuk Başlangıç (Cold-Start)	**Çok İyi:** İlk günlerde popülasyon sabit etkileriyle doğrudan makul bir başlangıç tahmini üretir.	**Çok İyi:** Popülasyon öncülü sayesinde az sayıda gece gözlemiyle hızla kişiye adapte olur.	**Orta:** Yeterli yerel etiket birikene kadar genelleme hatası yüksek kalabilir.
Açıklanabilirlik (Explainability)	**Yüksek:** Katsayılar doğrudan dakika başına ek gecikme olarak yorumlanabilir (+10 dk kullanım = +X dk gecikme).	**Yüksek:** Tahmin edilen süreyle birlikte güven aralığı ve belirsizlik yüzdesi sunulabilir.	**Düşük / Kara Kutu:** Kullanıcıya uyarının arkasındaki gerekçeyi matematiksel olarak açıklamak zordur.
Kaynak Tüketimi (Pil/Bellek)	**Çok düşük** (birkaç skaler çarpım).	**Çok düşük** (hafif analitik dağılım hesapları).	**Orta / Yüksek** (cihaz üzerinde inference ve tensör yükü).

Ölçüt	Karma Etkili Modeller (Mixed-Effects Models)	Bayesçi Güncelleme (Bayesian Updating)	Cihazda Öğrenme (LiteRT / On-Device ML)
Mahremiyet ve KVKK Uyumu	**Yüksek** (çıkarım katsayıları telefonda saklanır).	**En Yüksek** (tüm güncelleme yerel parametrelerde kalır).	**En Yüksek** (ham sensör verisi asla cihazdan çıkmaz).
Screen2Sleep AI Rolü	**Temel İstatistiksel Altyapı:** GLOBEM üzerindeki ana katsayı öğrenimi için seçilmiştir.	**Kişiselleştirme Motoru:** Sabahları yeni uyku verisi geldikçe katsayıları günden güne uyarlamak için seçilmiştir.	**Çalışma / Dağıtım İskeleti:** Android üzerinde arka planda pilden tasarruf ederek güvenli çıkarım yapmak için seçilmiştir.

Mevcut Çözümlerle Karşılaştırma Tablosu

Çözüm	Yaklaşım	Kişiselleştirme	Uyku odaklı mı	Anlık müdahale	Açıklanabilirlik	Gizlilik	Screen2Sleep farkı
Digital Wellbeing	Zamanlayıcı / odak modu	Düşük	Kısmen	Sınırlı	Yüksek	Yüksek	Uyku maliyeti tahmini yok
one sec	Sürtünme / öz-dürtme	Orta	Hayır	Evet	Orta	Belirtilmemiş	Uyku modeli yok
Time2Stop	Uyarlanabilir JITAI	Yüksek	Hayır	Evet	Yüksek	Belirtilmemiş	Uyku çıktısı yok
TypeOut	Yazma / öz-olumlama	Düşük–orta	Hayır	Evet	Orta	Belirtilmemiş	Uykuyu modellemez
Screen2Sleep	Oturum tahmini + uyku modeli	Yüksek	Evet	Evet	Hedef: yüksek	Hedef: cihazda işleme	Önerilen sistem

3.4 Kullanım Örnekleri

Gerçek dünya kullanım örnekleri ve projeye aktarımı:

Time2Stop: Sekiz haftalık saha çalışmasında uyarlanabilir ve açıklanabilir müdahale zamanlamasını test etmiş; Screen2Sleep için zamanlama, açıklama ve geri bildirim döngüsüne örnek oluşturur.

one sec: Hedef uygulamaya girişte kısa bekleme ve vazgeçme seçeneği sunar. Screen2Sleep, benzer "karar eşiği" mantığını yalnızca gece risk penceresinde ve uyku bağlamıyla kullanmayı hedefler.

TypeOut: Kısa bilişsel duraklama/öz-olumlama müdahalesinin saha karşılaştırmasını sunar. Proje, yazma görevi yerine daha düşük yükte tek bildirim ve kullanıcı seçimi kullanacaktır.

Android Digital Wellbeing: App timer, Focus Mode ve Bedtime Mode gibi yerleşik davranış yönetimi araçları sunar. Screen2Sleep'in farkı sabit program/limit yerine tahmine dayalı kişisel risk mesajı üretme hedefidir.

Oura/Fitbit/Health Connect: Giyilebilirler destekleyici uyku verisi sağlayabilir; ancak tüketici cihazlarında uyanıklık tespiti sınırlı olduğundan Screen2Sleep sabah öz-değerlendirmesini birincil ölçüm olarak korur.

YEDAM: Türkiye'de teknoloji/internet bağımlılığı dahil bağımlılık alanlarında 115 üzerinden ücretsiz psikososyal danışmanlık sağlar. Uygulama tanı veya tedavinin yerine geçmez; ihtiyaç duyan kullanıcıya isteğe bağlı profesyonel destek yönlendirmesi sunar.

3.5 Boşluklar, Riskler ve Fırsatlar

Mevcut araçlar ve projenin kendi tasarımı aşağıdaki riskleri doğurur:

1. **Yanlış kesinlik / nedensellik:** Gözlemsel ekran-uyku ilişkisi tek gecelik kesin "uyku kaybı" gibi gösterilmemelidir. Önlem: güven aralığı, kalibrasyon testi, nedensel olmayan dil ve kişisel referans karşılaştırması.
2. **Bildirim yorgunluğu ve yeni kompulsif döngü:** Çok sık uyarı kullanıcıyı ekrana daha fazla bağlayabilir. Önlem: yalnızca akşam penceresi, frekans sınırı, sessize alma ve ödül/streak mekanizmalarından kaçınma.
3. **Orthosomnia / uyku kaygısı:** Uyku skoruna aşırı odaklanma bazı kullanıcıların kaygısını artırabilir (Baron ve ark., 2017). Önlem: moralize etmeyen dil, kırmızı alarm puanlarından kaçınma, "yaklaşık" ve "belirsizlik" ifadeleri.
4. **Mahremiyet ve KVKK:** Uyku verileri sağlık verisi niteliğindedir; kullanım verileri uyku verisiyle birlikte işlendiğinde duyarlı davranış profili oluşturabilir. Önlem: veri minimizasyonu, amaçla sınırlılık, cihazda işleme tercihi, açık aydınlatma, gerekli hukuki işleme şartları, silme/erişimi geri alma seçenekleri.
5. **Adalet ve erişilebilirlik:** Giyilebilir cihazı olmayanlar, farklı Android sürümleri ve düzensiz vardiya düzenleri için model zayıflayabilir. Önlem: giyilebilirsiz kullanım, sabah öz-değerlendirmesi, alt-grup performans raporu ve desteklenmeyen durumda iddia azaltma.
6. **İzin/arka plan hataları:** İzin kapalı veya veri okunamıyor durumu "telefon kullanılmadı" diye yorumlanmamalıdır. Önlem: veri eksikliği durum kodları ve kullanıcıya şeffaf hata mesajı.
7. **Klinik sınır:** Screen2Sleep tanı, psikoterapi veya tıbbi tedavi sunmaz. Kalıcı uykusuzluk, yoğun sıkıntı veya kontrol kaybında kullanıcıya isteğe bağlı olarak hekim/psikolog ve YEDAM 115 yönlendirmesi sunulur.

Araştırma fırsatı: Projenin savunulabilir yenilik iddiası "ilk açıklanabilir JITAI" olmak değildir. Taranan çalışmalara göre daha dar boşluk; devam eden oturumun kalan süresi tahmini ile kişiye özgü uykuya dalma etkisini ortak bir zaman değişkeni üzerinden bağlayıp, belirsizliği açık bir gece müdahalesine dönüştürmektir. Bu bütünleşmenin etkisi pilotta sınanmalıdır.

3.6 Sonuç

Screen2Sleep AI için önerilen başlangıç yapısı; kullanım olaylarının UsageStatsManager ile okunması, ertelenebilir işlerin WorkManager ile yürütülmesi ve akşam izleme modunun Android çalışma kısıtlarına uygun biçimde uygulanmasıdır. Bu ayrım, günlük kullanım geçmişi oluşturma ile zamanında müdahale üretme gereksinimlerini ayrı olarak ele almaktadır.

Model A'da kişisel medyan referansının ardından açıklanabilir bir AFT modeli ve XGBoost-AFT karşılaştırılacaktır. Daha karmaşık sıralı modeller, basit yöntemlerin yetersiz kaldığı ve yeterli veri bulunduğu durumda değerlendirilecektir. Nihai seçim; doğruluk, belirsizlik kalibrasyonu, pil tüketimi ve cihazdaki çalışma maliyetine dayanacaktır.

Model B ve uyku ölçüm katmanıyla bütünleşmede kullanım pencereleri ve değişken tanımları açıkça eşleştirilmelidir. Mevcut oturumun kalan süresi, toplam akşam kullanımı ve uykuya dalma gecikmesi farklı büyüklüklerdir. Kişiselleştirme için yeterli veri miktarı da pilotta belirlenecek; belirli bir haftanın sonunda tam kişiselleşme garanti edilmeyecektir. Böylece teknoloji seçimi, projenin veriyle sınanabilir ve kullanıcıya anlaşılır tahminler sunma hedefine hizmet edecektir.

3.7 Kaynakça

Teknik dokümantasyon ve kurumsal kaynaklar — erişim tarihi: 12 Ekim 2026. Aşağıdaki bağlantılar güncel resmî dokümantasyon veya kurum sayfasıdır.

Android Developers. (t.y.). UsageStatsManager. https://developer.android.com/reference/android/app/usage/UsageStatsManager

Android Developers. (t.y.). UsageEvents.Event. https://developer.android.com/reference/android/app/usage/UsageEvents.Event

Android Developers. (t.y.). WorkManager / Define work requests. https://developer.android.com/develop/background-work/background-tasks/persistent/getting-started/define-work

Android Developers. (t.y.). Restrictions on starting a foreground service from the background. https://developer.android.com/develop/background-work/services/fgs/restrictions-bg-start

Android Developers. (t.y.). Foreground service types. https://developer.android.com/develop/background-work/services/fgs/service-types

Android Developers. (t.y.). Notification runtime permission. https://developer.android.com/develop/ui/views/notifications/notification-permission

Android Developers. (t.y.). SleepSessionRecord. https://developer.android.com/reference/androidx/health/connect/client/records/SleepSessionRecord

Android Developers. (t.y.). Develop sleep experiences with Health Connect. https://developer.android.com/health-and-fitness/health-connect/experiences/sleep

Google. (t.y.). Manage how you spend time on your Android phone with Digital Wellbeing. https://support.google.com/android/answer/9346420

Kişisel Verileri Koruma Kurumu. (t.y.). Özel nitelikli kişisel veriler. https://www.kvkk.gov.tr/

Yeşilay Danışmanlık Merkezi. (t.y.). YEDAM. https://www.yedam.org.tr/

lifelines. (t.y.). Survival regression. https://lifelines.readthedocs.io/

XGBoost Developers. (t.y.). Survival analysis with accelerated failure time. https://xgboost.readthedocs.io/

Akademik kaynaklar

Sano, A., Taylor, S., McHill, A. W., Phillips, A. J., Barger, L. K., Klerman, E., & Picard, R. (2018). Identifying Objective Physiological Markers and Modifiable Behaviors for Self-Reported Stress and Mental Health Status Using Wearable Sensors and Mobile Phones: Observational Study. Journal of Medical Internet Research, 20(6), e210. https://doi.org/10.2196/jmir.9410

Wang, R., Chen, F., Chen, Z., Li, T., Harari, G., Tignor, S., Zhou, X., Ben-Zeev, D., & Campbell, A. T. (2014). StudentLife: Assessing Mental Health, Academic Performance and Behavioral Trends of College Students using Smartphones. Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '14), 3–14. https://doi.org/10.1145/2632048.2632054

Xu, X., Liu, X., Zhang, H., Wang, W., Nepal, S., Sefidgar, Y., Seo, W., Kuehn, K. S., Huckins, J. F., Morris, M. E., Nurius, P. S., Riskin, E. A., Patel, S., Althoff, T., Campbell, A., Dey, A. K., & Mankoff, J. (2022). GLOBEM: Cross-Dataset Generalization of Longitudinal Human Behavior Modeling. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 6(4), Article 190, 1–34. https://doi.org/10.1145/3569485

Aliannejadi, M., Zamani, H., Crestani, F., & Croft, W. B. (2021). Context-aware target apps selection and recommendation for enhancing personal mobile assistants. ACM Transactions on Information Systems, 39(3), Article 29. https://doi.org/10.1145/3447678

Tian, Y., Zhou, K., & Pelleg, D. (2021). What and how long: Prediction of mobile app engagement [Ön baskı]. arXiv. https://arxiv.org/abs/2106.01490

Vasiloudis, T., Vahabi, H., Kravitz, R., & Rashkov, V. (2017). Predicting session length in media streaming. Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval. Association for Computing Machinery. https://doi.org/10.1145/3077136.3080695